Phương pháp cây quyết định

Chương 4.3: Khai phá dữ liệu

giangvlq@niem.edu.vn

Ngày 9 tháng 10 năm 2025

Những khái niệm cơ bản trong bài toán phân loại

- Nhắc lại khái niệm bài toán phân loại để tiện theo dõi
- Cho một tập bản ghi (tập huấn luyện): Mỗi bản ghi chứa tập thuộc tính, trong đó có **thuộc tính lớp** (chỉ thị phân loại)
- Mục tiêu: Tìm mô hình cho thuộc tính lớp như hàm của các thuộc tính khác
- Giá trị thuộc tính lớp được tính cho bản ghi mới, phân loại chính xác nhất có thể

Quy trình bài toán phân loại

Quy trình

- **Tập huấn luyện**: Dùng để xây dựng mô hình
- **Tập kiểm thử**: Xác định độ chính xác của mô hình

Minh họa quy trình:

- Quy nạp (Learn Model): Từ dữ liệu huấn luyện → Mô hình cây quyết định
- Suy diễn (Apply Model): Áp dụng cho dữ liệu kiểm thử

Ví dụ bảng dữ liệu:

Attrib1	Attrib2	Attrib3	Class
Yes	High	80K	Yes
No	Low	50K	No

Các ứng dụng của bài toán phân loại

- Dự đoán khối u **lành tính hay ác tính**
- Phân loại giao dịch thẻ tín dụng **hợp lệ hay gian lận**
- Phân loại cấu trúc thứ cấp của **protein**
- Phân loại tin tức: Tài chính, thời tiết, giải trí, thể thao, v.v.

Phương pháp phân loại bằng cây quyết định

Các phương pháp phân loại trong khai phá dữ liệu

- Dựa trên cây quyết định
- Dựa trên luật kết hợp
- Lập luận dựa trên ghi nhớ
- Mạng nơ-ron nhân tạo
- Mạng Bayes đơn giản/tổng quát
- Máy vectơ hỗ trợ

Tập trung: Phương pháp dựa trên cây quyết định

Cấu tạo cây quyết định

Cấu trúc cây quyết định

- **Cây quyết định**: Gồm nút trong (thuộc tính) và nút lá (giá trị lớp)
- Ví dụ: Từ bảng dữ liệu huấn luyện $\rightarrow$ Xây dựng cây
  - Nút trong: Refund, Marital Status, Taxable Income
  - Nút lá: Yes/No (Cheat)
- Có thể có nhiều cây từ cùng dữ liệu

Áp dụng mô hình cây quyết định

Quy trình áp dụng

1. Bắt đầu từ gốc cây (thuộc tính đầu tiên)
2. Dựa vào giá trị thuộc tính → Di chuyển xuống nhánh tương ứng
3. Tiếp tục đến nút lá → Lớp của bản ghi

Minh họa: Dữ liệu kiểm thử (Refund=No, Marital=Married, Taxable Income=80K) → **Cheat=No**

Các thuật toán tìm cây quyết định

Nhóm thuật toán

- Hunt (sớm nhất)
- **CART** (Classification and Regression Trees)
- ID3, C4.5
- SLIQ, SPRINT

Chiến lược tham lam: Phân tách bản ghi để tối ưu tiêu chí (GINI, Entropy, v.v.)

Thuật toán Hunt

Thuật toán Hunt

D_t: Tập bản ghi hướng tới nút t

- Nếu tất cả bản ghi cùng lớp $y_t \rightarrow$ Nút lá nhãn y_t
- Nếu D_t rỗng $\rightarrow$ Nút lá nhãn lớp mặc định y_d
- Nếu nhiều lớp $\rightarrow$ Phân chia bằng thuộc tính kiểm tra, áp dụng đệ quy

Ví dụ: Refund $\rightarrow$ Marital Status $\rightarrow$ Taxable Income

Xác định phân tách bản ghi

Các vấn đề cần giải quyết

- Xác định điều kiện kiểm tra thuộc tính
- Xác định phân tách tốt nhất
- Khi nào dừng phân tách

Phụ thuộc: Kiểu thuộc tính (tên, có trật tự, liên tục) và số nhánh (2 hoặc nhiều)

Phân tách cho thuộc tính tên

- **Phân nhiều nhánh**: Mỗi giá trị khác nhau $\rightarrow$ Một nhánh
  - Ví dụ: CarType: Family, Sports, Luxury
- **Phân nhị phân**: Chia thành 2 tập con, tìm phân tách tối ưu
  - Ví dụ: CarType {Family, Luxury} vs {Sports}

Phân tách cho thuộc tính có trật tự

- Tương tự thuộc tính tên
- **Phân nhiều nhánh**: Các giá trị phân biệt
  - Ví dụ: Size: Small, Medium, Large
- **Phân nhị phân**: Tìm phân tách tối ưu
  - Ví dụ: {Medium, Large} vs {Small}

Phân tách cho thuộc tính liên tục

- **Rời rạc hóa**: Tạo biến tĩnh/động (chia vùng bằng nhau hoặc phân cụm)
- **Phân nhị phân**: $A < v$ hoặc $A >= v$
- **Phân nhiều nhánh**: Các khoảng ngưỡng
  - Ví dụ: Taxable Income: $<$ 10K, [10K-25K), ...
- **Tìm ngưỡng**: Duyệt tất cả, chọn tốt nhất (tốn tính toán)

Chọn phân nhánh tốt nhất

Tiếp cận tham lam

Phân phối lớp đồng nhất được ưu tiên

Độ đo không đồng nhất (Impurity):

- Chỉ số GINI
- Độ Entropy
- Lỗi phân loại

Ưu tiên: Phân nhánh có độ không đồng nhất thấp

Chỉ số GINI

Công thức GINI

$GINI(t) = 1 - \sum[p(j|t)]^2$

- $p(j|t)$: Tần suất lớp j tại nút t

Giá trị:

- 0 (đồng nhất, thông tin ích nhất)
- Đến $1 - 1/n_c$ (không đồng nhất)

Ví dụ:

- C1:0, C2:6 $\rightarrow$ GINI=0
- C1:3, C2:3 $\rightarrow$ GINI=0.5

Tính GINI cho phân nhánh

Công thức

Với phân chia k phần: $GINI_{split} = \sum(n_i/n) \times GINI(i)$

Ví dụ:

- Nút cha GINI=0.5
- Con N1 GINI=0.194, N2=0.528
- $GINI_{children} = 0.333$

Sử dụng trong: CART, SLIQ, SPRINT

Giới thiệu Thuật toán CART

CART: Classification and Regression Trees

- Phát triển bởi Breiman et al. năm 1984
- Sử dụng cho cả **phân loại** và **hồi quy**
- **Đặc điểm chính**: Luôn phân tách **nhị phân**
- Ưu điểm: Dễ hiểu, xử lý dữ liệu lớn, không cần giả định phân phối

Quy trình xây dựng CART

1. Bắt đầu từ nút gốc chứa toàn bộ dữ liệu
2. Tại mỗi nút:
   - Duyệt qua tất cả thuộc tính và các điểm phân tách có thể
   - Chọn phân tách nhị phân tối ưu dựa trên tiêu chí giảm impurity lớn nhất
3. Đệ quy áp dụng cho các nút con
4. **Tiêu chí dừng**: Độ sâu tối đa, số mẫu tối thiểu, impurity $= 0$
5. **Sau xây dựng**: Tỉa cây (pruning) sử dụng cost-complexity pruning

Tiêu chí phân tách trong CART

Phân loại

Sử dụng **Gini Impurity**

- $Gini_{split} = \sum(n_i/n) \times Gini(i)$
- Chọn phân tách giảm Gini nhiều nhất

Hồi quy

Sử dụng **Mean Squared Error (MSE)**

- $MSE = \frac{1}{n}\sum(y_i - \hat{y})^2$
- Chọn phân tách giảm MSE nhiều nhất

Phân tách nhị phân: $A \leq v$ hoặc $A > v$

Ưu và nhược điểm của CART

Ưu điểm

- Dễ giải thích và trực quan hóa
- Xử lý dữ liệu không tuyến tính, missing values
- Không cần chuẩn hóa dữ liệu

Nhược điểm

- Dễ overfitting nếu không pruning
- Không ổn định: Dữ liệu thay đổi nhỏ có thể thay đổi cây lớn
- Thiên vị với thuộc tính có nhiều giá trị

Ứng dụng: Phân loại gian lận, dự đoán giá nhà, y tế

Giới thiệu Thuật toán ID3

ID3: Iterative Dichotomiser 3

- Phát triển bởi Ross Quinlan năm 1986
- Sử dụng **Entropy** và **Information Gain**
- **Phân tách đa nhánh** (một nhánh cho mỗi giá trị thuộc tính)
- Ưu điểm: Đơn giản, dễ giải thích
- Nhược điểm: Không xử lý tốt thuộc tính liên tục, dễ overfitting

Entropy và Information Gain trong ID3

Entropy

Đo độ không đồng nhất của dữ liệu:

$$Entropy(t) = -\sum [p(j|t) \log_2 p(j|t)]$$

Information Gain

Lượng thông tin thu được từ phân tách:

$$Gain(A) = Entropy(p) - \sum \frac{n_i}{n} Entropy(i)$$

Chọn thuộc tính có Information Gain cao nhất

Giới thiệu Thuật toán C4.5

C4.5: Cải tiến của ID3

- Phát triển bởi Ross Quinlan năm 1993
- Sử dụng **Gain Ratio** để tránh thiên vị:

$$GainRatio(A) = \frac{Gain(A)}{SplitInfo(A)}$$

- Hỗ trợ: Thuộc tính liên tục, giá trị missing, pruning
- Ưu điểm: Xử lý dữ liệu thực tế tốt hơn ID3

Giới thiệu thuật toán SLIQ và SPRINT

SLIQ (Supervised Learning In Quest)

- Phát triển bởi IBM năm 1996
- Sử dụng pre-sorting danh sách thuộc tính
- Sử dụng Gini Index cho phân tách

SPRINT

- Phiên bản mở rộng của SLIQ
- Hỗ trợ song song hóa
- Không cần rebuild tree khi dữ liệu thay đổi
- Scalable cho dữ liệu lớn (disk-based)

Tóm tắt

- Cây quyết định là phương pháp phân loại hiệu quả trong khai phá dữ liệu
- Ưu điểm: Dễ hiểu, dễ áp dụng, xử lý dữ liệu lớn
- Các thuật toán chính: CART, ID3/C4.5, SLIQ/SPRINT

Câu hỏi thảo luận:

- So sánh GINI với Entropy?
- Khi nào sử dụng CART vs C4.5?

Tài liệu tham khảo

- Breiman, L., et al. (1984). *Classification and Regression Trees*
- Quinlan, J.R. (1986). Induction of Decision Trees
- Quinlan, J.R. (1993). C4.5: Programs for Machine Learning
- Tài liệu bài giảng: Kho dữ liệu và kỹ thuật khai phá - PTIT