# KHAI PHÁ DỮ LIỆU - EDA

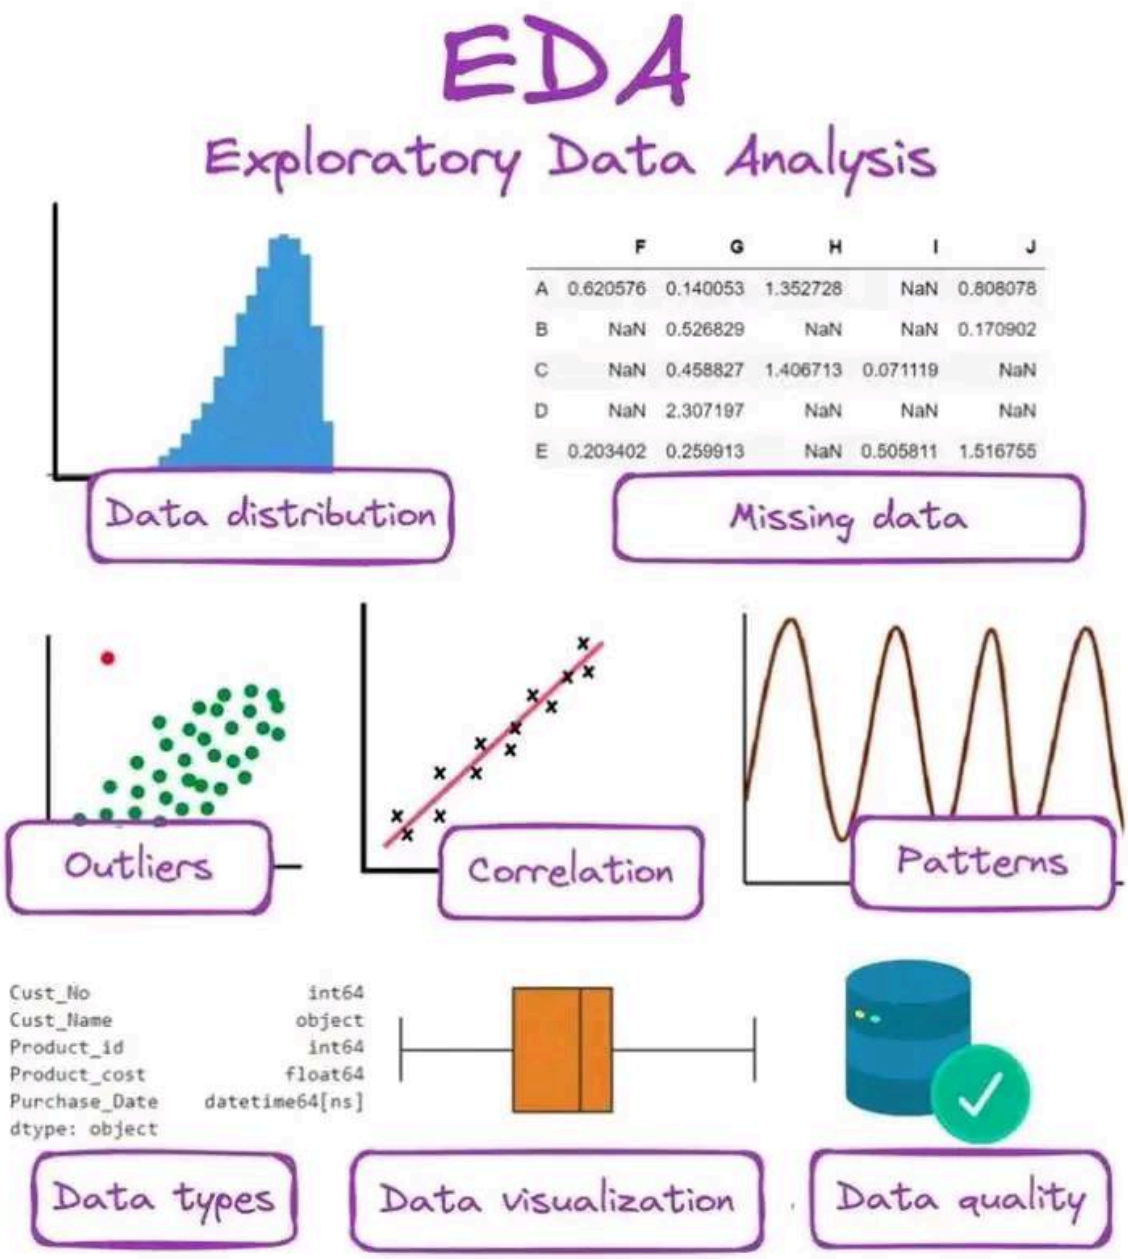


**PHẦN 1: TƯ DUY & CHIẾN LƯỢC (PRE-EDA)**

## 1.1. Khai phá dữ liệu là gì ?

**Khai phá dữ liệu - Exploratory Data Analysis (EDA)** : là bước **"bắt mạch" cho dữ liệu** (vital signs) nhằm tìm ra các mẫu (patterns), cấu trúc tiềm ẩn và các điểm bất thường trước khi xây dựng mô hình.

**Mục tiêu:** *Hiểu bối cảnh để không "lạc đường" khi phân tích.*

**Ví dụ:** Bạn có dữ liệu bán hàng. Nếu bạn chạy ngay mô hình dự báo doanh số mà không EDA, bạn có thể không nhận ra rằng dữ liệu tháng 12 bị nhập sai thành số 0 (do lỗi hệ thống). Mô hình sẽ học sai rằng "Tháng 12 không bán được hàng". EDA giúp bạn vẽ biểu đồ lên, thấy tháng 12 tụt xuống 0 -> phát hiện lỗi -> sửa dữ liệu -> mô hình đúng.

### 1.2 Định nghĩa bài toán & Giới hạn (Scope)

*Mục tiêu: Biến một yêu cầu kinh doanh mơ hồ thành một bài toán kỹ thuật cụ thể.*

a) Đặt các câu hỏi cốt lõi:

- Đây là việc xác định rõ dữ liệu này dùng để làm gì. Đừng hỏi chung chung mà một câu hỏi tốt phải xác định được **Đối tượng**, **Hành động** và **Thời gian.**
- Lưu ý: Dữ liệu có giới hạn. Nếu bạn đặt câu hỏi vượt quá giới hạn thông tin của dữ liệu, bạn sẽ nhận được câu trả lời sai hoặc sự ảo tưởng. Vì vậy, hãy giới hạn những câu hỏi **tại sao** mà dữ liệu không giải thích được. Hãy cố gắng tìm hiểu mọi thứ, thay vì tìm câu trả lời cụ thể.
- Phân loại các câu hỏi:
    + **Descriptive (Mô tả):** Chuyện gì **đã** xảy ra? (Dễ nhất).
    + **Predictive (Dự báo):** Chuyện gì **sẽ** xảy ra? (Cần mô hình).
    + **Causal (Nguyên nhân - Kết quả):** Tại sao nó xảy ra? (Khó nhất, EDA thường không đủ để khẳng định).
- **Vấn đề:** Các câu hỏi kinh doanh thường dùng tính từ định tính (tốt, mạnh, hiệu quả...).
- **Giải pháp:** Gán con số cụ thể cho các tính từ đó.

**Ví dụ 1:**

- **Sếp hỏi (Mơ hồ):** "Làm sao để tìm ra khách hàng **tiềm năng**?"
- **Tư duy EDA:** "Tiềm năng" nghĩa là gì?
    - Là người vào web xem hàng > 5 lần/tuần?
    - Hay là người đã bỏ hàng vào giỏ nhưng chưa thanh toán?
- **Câu hỏi cụ thể cần trả lời:** "Dựa vào lịch sử click chuột 3 ngày qua, hãy dự đoán xác suất khách hàng bấm nút 'Thanh toán' trong 24h tới."

**Ví dụ 2:**

- *Dữ liệu:* Quảng cáo Facebook và Doanh số bán áo thun.
- *Mô tả:* "Tháng trước chạy quảng cáo 50 triệu, bán được 500 cái áo." (OK).
- *Dự báo:* "Nếu tháng này chạy 100 triệu, sẽ bán được bao nhiêu?" (OK - dùng Hồi quy).

- *Nguyên nhân:* "Có phải quảng cáo làm tăng doanh số không, hay do tháng đó trùng vào dịp Tết nên tự nhiên người ta mua nhiều?"
    - *Cảnh báo:* EDA chỉ thấy Quảng cáo và Doanh số cùng tăng (Tương quan), nhưng không dám khẳng định Quảng cáo *gây ra* Doanh số. Đây là giới hạn.

b) Biến mục tiêu (Target Variable / Label - y)

- **Định nghĩa:** Là cột dữ liệu quan nhất hay cái đích mà bạn muốn nhắm đến để dự đoán hoặc phân tích sự biến động của nó.
- Hai bài toán xác định:
    + **Bài toán Supervised (Có giám sát):** Phải xác định rõ y là cột nào. Để dự đoán giá trị của y dựa trên các đặc trưng X.
        - Nếu y là số - dữ liệu liên tục (Doanh thu, Nhiệt độ) →Bài toán **Hồi quy (Regression)**.
        - Nếu y là nhãn - nhãn rời rạc (Có/Không, Chó/Mèo) →Bài toán **Phân loại (Classification)**.
    + **Bài toán Unsupervised (Không giám sát):** Không có y, mục tiêu là tìm cụm (cluster). Để hám phá cấu trúc tiềm ẩn trong dữ liệu.
        - **Clustering (phân cụm):** Gom nhóm dữ liệu thành các cụm dựa trên sự tương đồng. Ví dụ: Phân nhóm khách hàng theo hành vi mua sắm, phân cụm văn bản theo chủ đề.
        - **Dimensionality Reduction (giảm chiều):** Tìm cách biểu diễn dữ liệu trong không gian nhỏ hơn nhưng vẫn giữ thông tin quan trọng. Ví dụ: PCA, t-SNE

⚠️ **Vấn đề quan trọng: Mất cân bằng mẫu và phân phối lệch**

- Đây là bẫy lớn nhất trong bài toán giám sát. Xảy ra khi một nhóm trong biến mục tiêu y chiếm đa số áp đảo khiến biến y lệch hẳ về 1 phía.
- Công thức kiểm tra: $Tỷ\ lệ\ mất\ cân\ bằng\ = \frac{Số\ mẫu\ lớp\ thiểu\ số\ (Minority)}{Tổng\ số\ mẫu}$
- **Ngưỡng nguy hiểm:** Nếu tỷ lệ < 5% (hoặc 1:20), bạn đang gặp vấn đề nghiêm trọng.

**(1). Với bài toán Phân loại (Classification - Có/Không):**

- **Vấn đề: Mất cân bằng mẫu).**
- **Định nghĩa:** Khi phe này áp đảo phe kia về số lượng.
- **Rủi ro:** Mô hình sẽ lười biếng và đoán toàn bộ theo phe đông.

**Ví dụ: Phát hiện ung thư:**

- Dữ liệu: 1000 bệnh nhân.
- Bệnh nhân khỏe: 990 người (Lớp đa số).
- Bệnh nhân ung thư: 10 người (Lớp thiểu số - 1%).
- Nếu không xử lý (Upsampling/Downsampling) ngay từ bước EDA, mô hình sẽ phán: "Tất cả mọi người đều khỏe".

- Hậu quả: Độ chính xác = 99% (Accuracy = 99%). Nhưng KPI thực tế là phát hiện ung thư thì = 0. Dẫn đến bỏ sót người bị bệnh -> Thảm họa y tế.

-> Giải pháp EDA: Phải tách riêng phân phối của 2 nhóm này để so sánh, không gộp chung.

**Ví dụ 2:** Dự đoán khách hàng rời bỏ dịch vụ (Churn Prediction).

- **Biến mục tiêu (y):** Cột Is_Churn (1: Rời bỏ, 0: Ở lại).
- **Tình huống:** Trong 1000 khách, có 950 người ở lại (Số 0) và chỉ 50 người rời bỏ (Số 1).
- **Rủi ro:** Nếu bạn không xử lý (bằng cách SMOTE, Upsampling), mô hình sẽ lười biếng và đoán toàn bộ là "Ở lại". Độ chính xác vẫn là 95%, nhưng bạn mất sạch 50 khách hàng kia mà không hay biết.

**(2). Với bài toán Hồi quy (Regression - Dự đoán số):**

- **Vấn đề: Phân phối lệch (Skewness).**
- **Rủi ro:** Các giá trị quá lớn (Outlier) sẽ kéo lệch dự đoán của toàn bộ mô hình.

**Ví dụ:** Dự báo **thu nhập** trung bình của một nhóm người.

- Nhóm 10 người: 9 người lương 5 triệu, 1 ông tỷ phú lương 50 tỷ.
- Nếu tính trung bình cộng (Mean): Lương trung bình là 5 tỷ/người -> Sai bét.
- Trong EDA, cần phải phát hiện ra sự lệch này qua **Trung vị (Median)** hoặc lấy **Logarit** biến mục tiêu.

**c) KPIs**

Đừng chỉ nhìn vào con số của máy tính, hãy nhìn vào túi tiền của doanh nghiệp.

- **KPI Kỹ thuật (Technical Metrics):**
  - **RMSE (Root Mean Square Error):** Dùng cho dự báo số (giá nhà, doanh thu). Đơn vị giống đơn vị gốc. Sai số càng thấp càng tốt
  - **Precision (Độ chuẩn xác):** "Trong những cái tôi đoán là đúng, bao nhiêu cái thực sự đúng?".
  - **Recall (Độ nhạy):** "Trong những cái thực sự đúng, tôi tìm ra được bao nhiêu?".
  - **Accuracy (độ chính xác):**

**Ví dụ (Bộ lọc Spam Email):**

- **Tình huống:** Bạn viết code lọc thư rác.
- **Lựa chọn KPI:**
- Nếu tối ưu **Recall**: Thà bắt nhầm còn hơn bỏ sót -> Rủi ro: Thư mời họp quan trọng của sếp bị ném vào mục Spam.
- Nếu tối ưu Precision: Chỉ khi chắc chắn 100% là rác mới lọc -> An toàn cho thư quan trọng, nhưng hộp thư sẽ hơi nhiều rác.

-> Quyết định: Với Spam filter, Precision quan trọng hơn.

- **Metric Kinh doanh:** Lợi nhuận, Tỷ lệ giữ chân, Chi phí tiết kiệm,..

**Ví dụ :** Bài toán: **Gợi ý sản phẩm trên sàn E-commerce.**

- **Kỹ thuật:** Mô hình có độ chính xác 90% khi đoán khách thích món gì.
- **Kinh doanh:** Nhưng nếu mô hình toàn gợi ý món giá rẻ (cây bút bi, đôi tất), thì dù đoán đúng 100%, doanh thu vẫn thấp.
- **Chốt KPI:** "Tăng giá trị giỏ hàng trung bình (AOV) lên 10%," chứ không phải "Tăng độ chính xác mô hình".

### 1.3. Đánh giá Quy trình sinh dữ liệu (Data Generation Process)

#### a) Nguồn gốc Hành vi (Behavioral) vs. Khai báo (Attitudinal)

- **Dữ liệu Khai báo (Attitudinal):** Thu thập từ khảo sát, phỏng vấn.
  + *Đặc điểm:* Chứa cảm xúc, mong muốn, nhưng thường bị "làm màu" (xu hướng xã hội).
  + *Ví dụ:* Khi khảo sát "Bạn có hay tập thể dục không?", 80% trả lời "Có". Nhưng thực tế phòng Gym vắng tanh.

    -> Dữ liệu nhiễu

- **Dữ liệu Hành vi (Behavioral):** Thu thập từ Log hệ thống, lịch sử giao dịch, GPS.
  + *Đặc điểm:* Trung thực, tàn nhẫn, chính xác.
  + *Ví dụ:* Dữ liệu GPS từ đồng hồ thông minh cho thấy 80% người trả lời bên trên chỉ nằm ở nhà xem TV.

    -> Dữ liệu đáng tin cậcậy

*-> Kết luận:* Trong phân tích dữ liệu thường ưu tiên dữ liệu Hành vi (Behavioral) hơn.

#### b) Sampling Bias: các loại xu hướng chọn mẫu

Khi mẫu (Sample) của bạn không đại diện cho tổng thể (Population).

**(1). Selection Bias (xu hướng  chọn lựa)** Bạn chọn mẫu theo cách thuận tiện cho bạn, chứ không ngẫu nhiên.

> **Ví dụ cụ thể:** Bạn muốn tính **chiều cao trung bình của thanh niên Việt Nam**.

- *Cách làm sai:* Bạn chạy vào sân bóng rổ và đo chiều cao của mọi người ở đó vì... dễ gặp họ.
- *Kết quả:* Trung bình 1m85.
- *Sai lầm:* Bạn đã chọn một nhóm "đặc biệt" (người chơi bóng rổ thường cao) để đại diện cho tất cả. Dữ liệu này bị "Bias".

**(2). Non-response Bias (xu hướng  không phản hồi)** Sự im lặng cũng là dữ liệu. Những người *không trả lời* thường khác biệt hoàn toàn với những người *trả lời*.

- Ví dụ:
  Đánh giá sao trên Shopee/Foody.
  - Ai là người hay viết đánh giá nhất?
    1. Người cực kỳ ghét (món ăn có con ruồi).
    2. Người cực kỳ thích (được tặng voucher).
  - Những người thấy "ăn cũng được, bình thường" (chiếm 80%) thường **im lặng** và không viết gì.

-> **Kết quả:** Dữ liệu rating thường bị phân cực (nhiều 1 sao và 5 sao), thiếu hẳn mức 3 sao thực tế.

**(3). Survivorship Bias (xu hướng  kẻ sống sót)** Rủi ro nguy hiểm nhất trong phân tích tài chính và kinh doanh (Churn Analysis). Bạn chỉ phân tích những gì "còn lại" mà quên mất những gì "đã mất".

> **Ví dụ cụ thể (Kinh điển trong Churn Prediction):** Bạn muốn tìm hiểu: "Tại sao nhân viên gắn bó lâu dài với công ty?".

- **Dữ liệu:** Bạn lấy hồ sơ của toàn bộ nhân viên **đang làm việc** để phân tích.
- **Kết quả:** Bạn thấy ai cũng hài lòng về mức lương.

- **Sai lầm:** Những người **không hài lòng** về lương thì đã **nghỉ việc** từ lâu rồi, họ không còn nằm trong file dữ liệu nhân sự hiện tại nữa.
- **Khắc phục:** Phải lôi lại hồ sơ của cả những người đã nghỉ việc (The "dead" data) để so sánh.

Note : Khi phân tích dữ liệu khách hàng (Customer Churn), đừng chỉ nhìn vào khách hàng hiện tại. Hãy tìm cách moi lại dữ liệu của những khách hàng **đã bỏ đi** từ 5 năm trước. Đó mới là nơi chứa câu trả lời tại sao dịch vụ của bạn thất bại.

### 1.4. Quy trình 10 bước của Peng

BƯỚC 1: Đặt câu hỏi nghiên cứu (Formulate your question)

Đừng bao giờ lao vào phân tích mà không biết mình đang tìm gì. Dữ liệu rất lớn, nếu không có "đèn pin" (câu hỏi), bạn sẽ lạc trong bóng tối.

- **Chi tiết:** Câu hỏi cần cụ thể (Specific) và có thể trả lời được bằng dữ liệu (Answerable).
- **Ví dụ:**
  - *Sai (Quá chung chung):* "Hãy tìm insight từ bộ dữ liệu khách hàng này." -> Bạn sẽ vẽ 100 biểu đồ vô nghĩa.
  - *Đúng:* "Khách hàng mua hàng vào cuối tuần có xu hướng chi tiêu nhiều hơn khách hàng mua vào ngày thường không?" -> Bạn chỉ cần so sánh trung bình chi tiêu của 2 nhóm (T7-CN vs T2-T6).

BƯỚC 2: Đọc dữ liệu (Read in your data)

Nghe đơn giản nhưng đây là nơi 50% lỗi xảy ra. Bạn phải đảm bảo dữ liệu vào bộ nhớ máy tính đúng y hệt như dữ liệu gốc.

- **Chi tiết:** Chú ý các tham số khi load file (header, separator, encoding).
- **Cạm bẫy thường gặp:**
  - File CSV nhưng lại ngăn cách bằng dấu chấm phẩy (`;`) thay vì dấu phẩy (`,`).
  - File có các dòng chú thích ở đầu (ví dụ: 3 dòng đầu giới thiệu tên công ty).
- **Ví dụ:** Khi dùng `pd.read_csv('sales.csv')`, dữ liệu bị lỗi vì file gốc có 2 dòng đầu là tiêu đề báo cáo.
  - *Khắc phục:* `pd.read_csv('sales.csv', skiprows=2)`.

BƯỚC 3: Kiểm tra "bao bì" (Check the packaging)

Trước khi mở quà, hãy nhìn hộp quà. Số lượng dòng cột nói lên rất nhiều điều về tính khả thi của phân tích.

- **Chi tiết:** Kiểm tra `nrow` (số dòng), `ncol` (số cột), và kích thước file (MB/GB).
- **Ví dụ:**
    - Bạn có 1 file dữ liệu "Toàn bộ dân số Việt Nam" nhưng khi check `nrow` chỉ thấy có 10,000 dòng.
    - *Kết luận:* Đây chỉ là mẫu thử (sample), không phải dữ liệu toàn bộ. Mọi kết luận về "tổng dân số" sẽ bị sai nếu bạn nhân hệ số không đúng.

BƯỚC 4: Kiểm tra cấu trúc (Run `str()`)

Đây là bước "soi kính hiển vi" vào từng cột. Bước này trả lời câu hỏi: *Máy tính đang hiểu cột này là cái gì?*

- **Chi tiết:** Xem Class (loại dữ liệu) của từng biến.
- **Ví dụ kinh điển:**
    - Cột `Mã Bưu Điện` (Zipcode): 01000 (Hà Nội).
    - Máy tính hiểu là **Số** (Integer) -> Nó tự động xóa số 0 ở đầu -> Thành `1000`.
    - *Hậu quả:* Sai lệch thông tin địa lý. Bạn phải ép kiểu về **Chuỗi** (String/Character).
    - Cột `Ngày tháng`: Dữ liệu là "20/10/2023" nhưng máy hiểu là **String**. Bạn không thể vẽ biểu đồ theo thời gian nếu không chuyển về **Datetime**.

BƯỚC **5: Nhìn đầu và đuôi (Look at the top and the bottom)**

Đừng chỉ nhìn 5 dòng đầu (`head`). "Rác" thường bị quét xuống dưới gầm giường (`tail`).

- **Chi tiết:** Kiểm tra xem dữ liệu có đồng nhất từ đầu đến cuối không.
- **Ví dụ:**
    - Dùng `tail(data)` và phát hiện dòng cuối cùng ghi: *"Nguồn: Tổng cục Thống kê, xuất ngày 12/12"*.
    - Nếu không xóa dòng này, khi bạn tính toán cột "Doanh thu", máy tính sẽ báo lỗi vì dòng cuối chứa chữ, hoặc tệ hơn, nó coi dòng đó là một khách hàng tên là "Nguồn".

BƯỚC **6: Kiểm tra các số đếm (Check your "n"s)**

Đếm tần suất xuất hiện của các giá trị để tìm sự vô lý. Roger Peng gọi đây là bước tìm "Landmarks" (cột mốc).

- **Chi tiết:** Dùng `value_counts()` (Python) hoặc `table()` (R) cho các biến phân loại. Kiểm tra các mốc thời gian (Min/Max date).
- **Ví dụ:**
  - Cột `Giới tính`: Bạn đếm thấy có 500 Nam, 490 Nữ và **10 "Alien"** (người ngoài hành tinh). -> Lỗi nhập liệu.
  - Cột `Thời gian`: Dữ liệu bán hàng năm 2023, nhưng khi check `min(date)` lại thấy năm **1970** (do lỗi Unix Timestamp mặc định) hoặc `max(date)` là năm **2999**.

### BƯỚC **7: Đối chiếu nguồn ngoài (Validate with external data source)**

Đừng tin mù quáng vào dữ liệu nội bộ. Hãy tìm một "ngọn hải đăng" bên ngoài để so sánh.

- **Chi tiết:** Số liệu của bạn có khớp với các báo cáo công khai hoặc logic thông thường không?
- **Ví dụ:**
  - Dữ liệu của bạn cho thấy tỷ lệ người thất nghiệp ở TP.HCM là **0.5%**.
  - *Đối chiếu:* Tìm báo cáo của Tổng cục Thống kê, thấy con số thực tế khoảng **2-3%**.
  - *Kết luận:* Dữ liệu của bạn đang bị sai (có thể do chỉ khảo sát nhóm người có thu nhập cao) hoặc định nghĩa "thất nghiệp" của bạn khác họ.

### BƯỚC **8: Thử giải pháp đơn giản trước (Try the easy solution first)**

Đừng vội dùng Deep Learning hay thuật toán phức tạp. Hãy vẽ một biểu đồ đơn giản.

- **Chi tiết:** Dùng Boxplot hoặc Histogram để trả lời câu hỏi ở Bước 1.
- **Ví dụ:**
  - Câu hỏi: "Quận nào có giá nhà cao nhất?"
  - *Giải pháp đơn giản:* Vẽ Boxplot giá nhà theo từng Quận. Nhìn cái là thấy ngay Quận 1 cao nhất, Quận Gò Vấp thấp hơn. Xong. Đôi khi bạn không cần mô hình dự báo phức tạp để biết điều này.

### BƯỚC **9: Thách thức giải pháp của bạn (Challenge your solution)**

Hãy đóng vai "Luật sư của quỷ" (Devil's Advocate). Hãy cố gắng chứng minh mình sai.

- **Chi tiết:** Tìm các biến nhiễu (Confounding variables), xem xét các yếu tố địa lý, thời gian.
- **Ví dụ:**
    - *Kết quả:* Bạn thấy "Người uống cà phê nhiều thì sống thọ hơn".
    - *Thách thức:* Có thật là do cà phê không? Hay là do những người uống cà phê thường là người giàu -> Có tiền chăm sóc sức khỏe tốt hơn? (Ở đây "Sự giàu có" là biến nhiễu). Bạn cần vẽ lại biểu đồ nhưng phân tách theo nhóm thu nhập.

BƯỚC **10: Tiếp nối (Follow up)**

EDA là một vòng lặp, không phải đường thẳng. Kết thúc bước 9 sẽ mở ra bước 1 mới.

- **Chi tiết:**
    - Bạn có cần thêm dữ liệu không?
    - Bạn có cần lọc bỏ bớt dữ liệu nhiễu không?
    - Mô hình nào là phù hợp?
- **Ví dụ:** Sau khi thách thức ở Bước 9, bạn nhận ra mình thiếu dữ liệu về "Thu nhập" để kiểm chứng giả thuyết cà phê.
    - *Hành động:* Yêu cầu bộ phận IT thu thập thêm dữ liệu thu nhập, hoặc tìm dataset bổ sung. Quay lại Bước 1 với câu hỏi mới.

## 1.5: Xây dựng từ điển dữ liệu

*Mục tiêu: Có bản "Hướng dẫn sử dụng" trước khi bắt đầu dùng sản phẩm.*

a) Ý nghĩa:

Dữ liệu thô chỉ là những con số vô hồn. Nếu không có từ điển, khi phân tích rất sẽ rơi vào các cái bẫy  của dữ liệu.

- **Ví dụ:** Cột Thời gian ghi là 100.
    - Là 100 giây? 100 phút? hay 100 giờ?
- **Ví dụ:** Cột Tình trạng ghi là 0 và 1.
    - 1 là thành công hay thất bại? 1 là Nam hay Nữ?

b) Các thành phần bắt buộc của Data Dictionary

Nên tạo một file Excel hoặc Sheet riêng mô tả từng cột trong bộ dữ liệu với các thông tin sau:

| Tên Cột (Variable Name) | Ý nghĩa (Definition) | Kiểu dữ liệu (Data Type) | Đơn vị tính (Unit) | Giá trị cho phép (Allowed Values) | Ghi chú (Notes) |
|---|---|---|---|---|---|
| trans_amount | Giá trị giao dịch | Float | **nghìn VNĐ** | > 0 | Đã bao gồm VAT chưa? |
| status_id | Trạng thái đơn | Categorical (Int) | N/A | 1=Mới, 2=Đang giao, 3=Hủy | **Quan trọng:** Chỉ tính doanh thu với mã 4 (Hoàn thành) |
| cust_age | Tuổi khách hàng | Int | Năm | 18 - 100 | Tính theo năm sinh trên CMND |

c) Cách xử lý khi KHÔNG có tài liệu (Thực tế phổ biến)

90% dự án thực tế bạn nhận được file CSV mà không có tài liệu đi kèm. Bạn phải làm gì?

01. **Truy vấn ngược (Reverse Engineering):**
    a. Chạy lệnh value_counts() để đoán. (Ví dụ thấy cột Gender có giá trị 0 chiếm 50%, 1 chiếm 50% -> đoán là Nam/Nữ).
02. **Phỏng vấn chủ sở hữu (Interview Data Owner):**
    a. Hỏi trực tiếp người xuất file dữ liệu: "Anh ơi, cột discount này là số tiền giảm hay phần trăm giảm?".
03. **Tự tạo tài liệu:** Sau khi hỏi xong, hãy tự viết lại và lưu lại. Đó là tài sản của dự án.

**PHẦN 2: KIỂM TRA DỮ LIỆU**

*Mục tiêu: Đảm bảo dữ liệu "sạch" về mặt kỹ thuật trước khi phân tích thống kê.*

## 2.1. Kiểm tra Cấu trúc & Định dạng (Structure & Types)

### (1) Kích thước

- **Định nghĩa:** Bạn kiểm tra tỷ lệ giữa số dòng ( n - số quan sát) và số cột ( p - số biến).

- **Quy tắc vàng:** n phải lớn hơn rất nhiều so với p ( n \gg p ).
- **Số chiều dữ liệu :** Khi số cột ( p ) quá lớn mà số dòng ( n ) lại ít, dữ liệu trở nên "loãng" trong không gian nhiều chiều. Mọi điểm dữ liệu đều trở nên xa nhau, khiến việc tìm ra mẫu (pattern) giống như tìm kim đáy bể.

**Ví dụ:**

- **Tốt ( n > p ):** Bạn khảo sát 1,000 người ( n ) về 5 câu hỏi ( p ). Dữ liệu đủ dày để thấy xu hướng chung.
- Xấu (Curse of Dimensionality): Bạn có dữ liệu gen của 5 bệnh nhân ( n=5 ) nhưng lại đo tới 20,000 mã gen ( p=20,000 ).
  →Hậu quả: Máy tính sẽ tìm thấy hàng ngàn quy luật ngẫu nhiên vô nghĩa (ví dụ: "Gen số 1534 gây ung thư") chỉ vì ngẫu nhiên 2 bệnh nhân cùng có gen đó, nhưng thực tế không đúng.

### (2) Định dạng & "Implicit Casting" (Ép kiểu ngầm định)

**Định nghĩa:** Máy tính rất máy móc. Nó không hiểu ngữ nghĩa, chỉ hiểu ký tự.

- **Implicit Casting:** Khi một cột số chứa 1 ký tự lạ, toàn bộ cột đó bị biến thành dạng Văn bản (Object/String).

**Ví dụ cụ thể:**

- Cột Giá sản phẩm:
  - Dữ liệu: 100, 200, 300, " 400".
  - Lỗi: Vì có dấu , máy hiểu cả cột này là chữ.
  - Hậu quả: Khi bạn lệnh Mean(Giá sản phẩm), máy báo lỗi (không thể cộng chữ).
    →Xử lý: Phải dùng hàm replace để xóa dấu , , sau đó ép kiểu về float.

### (3) Factor/Categorical (Biến phân loại) - Nominal vs. Ordinal

Việc phân biệt này quyết định cách bạn mã hóa dữ liệu (Encoding) cho mô hình.

- **Nominal (Danh nghĩa):** Các nhóm ngang hàng nhau, không ai hơn ai.
  **Ví dụ:** Cột Màu sắc (Đỏ, Xanh, Vàng).
  - **Xử lý:** Dùng **One-Hot Encoding** (Tách thành 3 cột riêng: is_Red, is_Blue, is_Yellow). Không được gán Đỏ=1, Xanh=2, Vàng=3 vì máy sẽ hiểu nhầm Vàng > Đỏ.
- **Ordinal (Thứ bậc):** Các nhóm có trật tự to nhỏ rõ ràng.
  **Ví dụ:** Cột Trình độ học vấn (Cấp 1 < Cấp 2 < Cấp 3 < Đại học).
  - **Xử lý:** Phải gán số thứ tự: Cấp 1 = 1, Cấp 2 = 2, Cấp 3 = 3... Trong R, dùng lệnh factor(x, levels=c("Cap1", "Cap2"...), ordered=TRUE) để máy hiểu sự so sánh này.

#### (4) Nguyên tắc Tidy Data (Dữ liệu ngăn nắp) - Wickham

Đây là chuẩn mực của dữ liệu sạch. Dữ liệu sạch phải tuân thủ 3 luật:

01. Mỗi biến là 1 cột.
02. Mỗi quan sát là 1 dòng.
03. Mỗi ô chỉ chứa 1 giá trị.

- **Ví dụ vi phạm (Dữ liệu bẩn):**
  - Cột `Thông tin` chứa: *"Nguyễn Văn A - 25 tuổi - Hà Nội"*.
  - *Tại sao tệ?* Bạn không thể tính tuổi trung bình hay lọc người ở Hà Nội được.
  - *Xử lý:* Tách thành 3 cột: `Tên`, `Tuổi`, `Thành phố`.
- **Ví dụ vi phạm (Cột chứa giá trị):**
  - Bảng doanh thu có các cột: `Tháng 1`, `Tháng 2`, `Tháng 3`.
  - *Tại sao tệ?* Tên cột đang chứa dữ liệu (thời gian). Khó vẽ biểu đồ biến thiên theo thời gian.
  - *Xử lý (Pivot/Melt):* Chuyển về 2 cột: `Tháng` và `Doanh thu`.

### 2.2. Xử lý Dữ liệu thiếu (Missing Data)

#### (1) Phân tích cơ chế thiếu (Mechanism) - Quan trọng nhất!

Trước khi điền số, phải hỏi "Tại sao nó thiếu?".

- **MCAR (Missing Completely At Random - Ngẫu nhiên hoàn toàn):** Việc thiếu không liên quan gì đến giá trị dữ liệu.
  Ví dụ: Một chồng phiếu khảo sát bị gió thổi bay mất 5 tờ. Những tờ mất này là

ngẫu nhiên.
→Xử lý: Xóa dòng đó đi hoặc điền trung bình đều an toàn.

- **MNAR (Missing Not At Random - Thiếu có chủ đích):** Việc thiếu chính là một thông tin quan trọng.
  **Ví dụ:** Khảo sát về cân nặng. Những người béo phì thường **bỏ trống** câu hỏi này vì ngại.
    - Nếu bạn điền giá trị trung bình (ví dụ 60kg) vào những ô trống này -> Bạn đã làm sai lệch thực tế (thực tế họ có thể 90kg).
      →Xử lý: Tạo thêm cột da_giau_can_nang (Yes/No). Mô hình sẽ học được rằng: "Hễ ai giấu cân nặng thì nguy cơ bệnh tim cao hơn".

#### (2) Phương pháp điền khuyết (Imputation)

- **Cách đơn giản (Mean/Median):** Nhanh nhưng làm giảm phương sai của dữ liệu (làm dữ liệu bớt biến động nhân tạo).
  **Ví dụ:** Lớp học có 1 bạn nghỉ thi. Bạn lấy điểm trung bình cả lớp (7.0) gán cho bạn đó.
  - **Cách nâng cao (KNN Imputation - K láng giềng gần nhất):** Thông minh hơn. "Hãy nhìn những người giống bạn nhất".
    **Ví dụ:**
    - Dữ liệu thiếu: Ông A (40 tuổi, Kỹ sư) không khai báo lương.
    - Thuật toán KNN: Tìm trong dữ liệu xem những người khác "cũng 40 tuổi" và "làm Kỹ sư" đang có lương bao nhiêu? (Ví dụ: 20 triệu).
    - Điền: Gán 20 triệu cho ông A. Cách này chính xác hơn nhiều so với lấy trung bình cả xã hội.

### 2.3. Kiểm tra tính nhất quán (Consistency)

#### (1) Lỗi chính tả trong biến phân loại

Dữ liệu do con người nhập tay thường rất bẩn.

**Ví dụ:** Cột Thành phố:

- Giá trị xuất hiện: "TP.HCM", "tp hcm", "HCMC", "Ho Chi Minh City".
- Hậu quả: Khi gom nhóm (groupby), máy tính sẽ chia thành 4 nhóm khác nhau thay vì 1.

→Xử lý: Chuẩn hóa tất cả về chữ thường, bỏ dấu câu, mapping về 1 chuẩn duy nhất (ví dụ: "hcm").

#### (2) Lỗi Logic (Logical Errors)

Dữ liệu có thể đúng định dạng (là số, là ngày) nhưng sai về mặt logic thực tế.

**Ví dụ:**

- **Dữ liệu Thời gian:** Ngày ký hợp đồng (2023) lại nhỏ hơn Ngày sinh khách hàng (2025)? -> Vô lý (Khách chưa đẻ đã ký HĐ).
- **Dữ liệu Tuổi:** Khách hàng 5 tuổi nhưng có thu nhập 1 tỷ/năm? -> Có thể nhầm lẫn đơn vị hoặc nhập sai cột.
- **Dữ liệu Âm:** Thời gian xử lý đơn hàng = -5 phút? -> Vô lý.

### 2.4. Dữ liệu trùng lặp

*Mục tiêu: Đảm bảo mỗi sự kiện/đối tượng chỉ được đếm một lần duy nhất.*

#### (1). Trùng lặp hoàn toàn (Exact Duplicates)

- **Nhận diện:** Hai dòng dữ liệu giống nhau 100% ở tất cả các cột.
- **Nguyên nhân:**
  - Lỗi hệ thống ghi log 2 lần (Network retry).
  - Lỗi người dùng bấm nút "Gửi" 2 lần liên tiếp (Double Click).
  - Lỗi khi Join bảng (Cartesian Product) làm nhân bản dòng.
- **Ví dụ:**
  - Dòng 1: `ID=A1, Mua=Bánh, Giá=10k`
  - Dòng 2: `ID=A1, Mua=Bánh, Giá=10k`
- **Xử lý:** Xóa ngay lập tức. Giữ lại 1 dòng duy nhất.
  - *Code (Python):* `df.drop_duplicates(inplace=True)`

#### (2). Trùng lặp một phần / Trùng lặp ID (Partial Duplicates) - *Khó & Nguy hiểm*

- **Nhận diện:** Cùng một khóa chính (`TransactionID` hoặc `CustomerID`) nhưng nội dung các cột khác lại khác nhau (thường là thời gian hoặc trạng thái).
- **Nguyên nhân:** Dữ liệu cập nhật theo thời gian (SCD Type 2). Hệ thống ghi nhận mọi thay đổi trạng thái của đơn hàng.
- **Ví dụ thực tế:**

    - Dòng 1: `Mã Đơn=DH001`, `Trạng thái=Đang giao`, `Thời gian=8:00 AM`
    - Dòng 2: `Mã Đơn=DH001`, `Trạng thái=Giao thành công`, `Thời gian=10:00 AM`
- **Cạm bẫy:** Nếu bạn tính tổng đếm (`count`), bạn sẽ báo cáo: "Có 2 đơn hàng". Sai! Chỉ có 1 đơn hàng nhưng cập nhật 2 lần.
- **Xử lý (Business Logic Deduplication):**
    - **Quy tắc:** "Chỉ giữ lại trạng thái mới nhất".
    - **Cách làm:**
        1. Sắp xếp dữ liệu theo `Mã Đơn` và `Thời gian` (giảm dần).
        2. Giữ lại dòng đầu tiên của mỗi `Mã Đơn`.

(3). Trùng lặp ngẫu nhiên (False Positives / Collisions) - *Hiếm gặp nhưng cần biết*

- **Tình huống:** Hai người khác nhau nhưng lại có tên giống hệt nhau và ngày sinh giống hệt nhau.
- **Ví dụ:** Có 2 ông "Nguyễn Văn A" cùng sinh ngày 01/01/1990.
- **Cách kiểm tra:** Nếu bạn định xóa trùng lặp dựa trên Tên + Ngày sinh, bạn sẽ xóa nhầm người.
- **Lời khuyên:** Luôn luôn tìm một mã định danh duy nhất (Unique ID) như số CMND, Mã khách hàng (User ID) để làm căn cứ xóa trùng lặp. Không bao giờ deduplicate dựa trên tên người.

**Phần 3: Phân tích biến đơn**

*Nguyên tắc "Đừng tin vào thống kê tóm tắt, hãy nhìn vào phân phối".*

3.1. Biến Số (Numerical Variables)

**a) Ước lượng vị trí -** để tìm ra "trọng tâm" thực sự của dữ liệu, nơi đại diện tốt nhất cho cả tập hợp.

(1) Trimmed Mean (Trung bình cắt ngọn)

- **Định nghĩa kỹ thuật:** Là trung bình cộng (Mean) được tính sau khi đã loại bỏ **p% giá trị nhỏ nhấ**t và **p% giá trị lớn nhất** của tập dữ liệu đã sắp xếp. ( Nên cắt 10%)
- **Ý nghĩa:** Để đạt được tính **Bền vững**.
    - *Mean:* Quá nhạy cảm. Một sai số nhỏ ở cực (outlier) làm hỏng kết quả và chỉ cần 1 giá trị cực lớn cũng kéo lệch cả kết quả.

- *Median:* Quá lãng phí. Nó bỏ qua độ lớn của các giá trị, chỉ quan tâm thứ tự.
- *Trimmed Mean:* Lấy ưu điểm cả hai, giúp loại bỏ ảnh hưởng này mà không làm mất quá nhiều thông tin

**Ví dụ:** Tính thời gian xử lý đơn hàng (phút).

- Dữ liệu: [2, 3, 3, 4, 5, 5, 6, 900] (900 phút là do nhân viên quên bấm "Hoàn thành" đi về ngủ).
- **Mean:** $\frac{2+3+3+4+5+5+6+900}{8} \approx 116\ phút$ (Sai lệch khủng khiếp).
- **Median:** 4.5 phút (Hơi chủ quan).
- **Trimmed Mean (cắt 10% - bỏ số 2 và 900):** Trung bình của [3, 3, 4, 5, 5, 6] = **4.3 phút**. ->Đây là con số chính xác để báo cáo KPI.

(2) Weighted Mean (Trung bình có trọng số)
**Định nghĩa:** Mỗi giá trị dữ liệu ($x_i$) được nhân với một trọng số ($w_i$) tương ứng với tầm quan trọng của nó.

Công thức: $\bar{x} = \frac{\sum_{i=1}^{n} w_i x_i}{\sum_{i=1}^{n} w_i}$

**Ý nghĩa:** Dùng để sửa lỗi **xu hướng chọn mẫu**. Khi mẫu thu thập không đại diện đúng tỷ lệ của tổng thể.

**Ví dụ:** Đánh giá mức độ hài lòng của nhân viên toàn công ty (Thang điểm 10).

- Công ty có: 100 ông Kỹ thuật (Tech) và 10 ông Kinh doanh (Sales).
- Khảo sát thu được: 10 phiếu từ Tech (TB điểm = 8) và 10 phiếu từ Sales (TB điểm = 5).
- **Mean thường:** (8 + 5) / 2 = 6.5 . (Sai, vì coi Tech và Sales ngang nhau).
- **Weighted Mean:** Vì Tech đông gấp 10 lần Sales, ta gán trọng số w_{tech}=10, w_{sales}=1 .
- Kết quả: \frac{8 \times 10 + 5 \times 1}{11} \approx 7.7 . \rightarrow Điểm hài lòng thực tế cao hơn nhiều.

**(3) Mode (Yếu vị)**

- **Định nghĩa:** Giá trị xuất hiện nhiều nhất trong tập dữ liệu.

- **Ứng dụng:**
    - Dùng để điền dữ liệu thiếu (Imputation) cho biến phân loại.
    - Giúp phát hiện **Phân phối đa đỉnh (Multimodal)**. Nếu Mean = 5, Median = 5 nhưng Mode là 2 và 8 -> Dữ liệu có 2 nhóm đối tượng riêng biệt (ví dụ: nhóm khách mua sỉ và mua lẻ). Mean/Median đã che giấu điều này

**Ví dụ:** Lương công ty: Sếp 100tr, Nhân viên 5tr.

- Mean: 20tr (ảo). Median: 5tr.
- **Mode:** 5tr (Cho biết mức lương phổ biến nhất thực sự là bao nhiêu).

b) Ước lượng biến thiên: dùng để đo lường độ tin cậy. Dữ liệu càng biến thiên ⇔ độ tin cậy càng thấp.

**(1). MAD (Median Absolute Deviation - Sai số tuyệt đối trung vị)**

- **Định nghĩa:** Là trung vị của các khoảng cách từ mỗi điểm dữ liệu đến trung vị cchungcuar toàn bộ dữ liệu .
    - Bước 1: Tìm Median của tập dữ liệu (M).
    - Bước 2: Tính độ lệch tuyệt đối của từng điểm: $|x_i$ - M|.
    - Bước 3: Tìm Median của các độ lệch đó.
- Đây là chỉ số bị đánh giá thấp nhất (underrated) và là phiên bản "anh em sinh đôi" mạnh mẽ hơn của Độ lệch chuẩn (SD). MAD miễn nhiễm với Outlier, trong khi Độ lệch chuẩn (SD) thì bị ảnh hưởng. Nếu SD >> MAD (SD lớn hơn MAD rất nhiều): Chắc chắn dữ liệu có Outliers cực lớn đang thổi phồng SD.

**Ví dụ:**

- Lớp A điểm thi: [7, 8, 7, 8, 8].
    - Median = 8.
    - Độ lệch: |7-8|=1, |8-8|=0... ->MAD rất nhỏ. SD cũng nhỏ.
- Lớp B (có lỗi nhập liệu): [7, 8, 7, 8, 1000].
    - Median vẫn là 8.
    - **MAD vẫn nhỏ** (vì nó phớt lờ số 1000).
    - **SD tăng vọt** lên hàng trăm.

-> Nhìn vào sự chênh lệch SD và MAD, ta phát hiện ngay số 1000 là bất thường.

**(2). IQR (Interquartile Range - Khoảng tứ phân vị)**: Đo độ rộng của "số đông" (50% dữ liệu ở giữa), bỏ qua các thành phần cực đoan.

- **Định nghĩa:** IQR là khoảng cách giữa Phân vị thứ 75 (Q3) và Phân vị thứ 25 (Q1). Về mặt hình ảnh: Trong biểu đồ Boxplot, IQR chính là chiều cao (hoặc chiều dài) của cái "Hộp".
- Công thức: IQR = Q3 - Q1
- **Ý nghĩa:** đạt được tính bền vững- cũng giống như Median, IQR không bị ảnh hưởng bởi Outliers.
    - **Range (Khoảng biến thiên):** Max - Min. Chỉ cần 1 tỷ phú bước vào xóm nghèo, Max tăng vọt \rightarrow Range tăng vọt \rightarrow Sai lệch.
    - **IQR:** Chỉ quan tâm đến khúc giữa (từ người nghèo thứ 25 đến người giàu thứ 75). Tỷ phú (nằm ở top 100) bị loại ra khỏi phép tính này.
- **Công cụ phát hiện Outlier (Tukey's Fences):** Đây là tiêu chuẩn vàng để lọc nhiễu trong EDA: Bất kỳ điểm nào nằm ngoài khoảng: [Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR] đều bị coi là **Outlier**.

**Ví dụ:**

- Tình huống: Khảo sát số giờ làm thêm (OT) mỗi tháng của 1 nhóm lập trình viên.
- Dữ liệu: [0, 10, 12, 15, 18, 20, 100] (Người cuối cùng OT 100 giờ - có thể do lỗi máy chấm công hoặc là "siêu nhân").
- **Phân tích:**
    - Sắp xếp: 0, 10, 12, 15, 18, 20, 100.
    - Q1 (25%): Khoảng 10.
    - Q3 (75%): Khoảng 20.
    - **IQR** = 20 - 10 = 10 . (Độ rộng của nhóm nhân viên bình thường là 10 giờ).
    - **Range (Max - Min)** = 100 - 0 = 100 . (Con số này làm sếp tưởng anh em OT lung tung lắm).
- **Tìm Outlier bằng IQR:**
    - Ngưỡng trên = Q3 + 1.5 \times IQR = 20 + 1.5 \times 10 = 35 .
    - So sánh: Giá trị 100 > 35.

\rightarrow **Kết luận:** Số 100 là Outlier. Cần kiểm tra lại máy chấm công.

### c) Phân phối & Trực quan hóa: Nhìn thấy được hình dáng của dữ liệu

(1). Histogram: Biểu đồ tần suất

- **Định nghĩa:** Chia dữ liệu thành các khoảng (bins) bằng nhau và đếm số lượng rơi vào mỗi khoảng.
- **Lý thuyết:** Giúp nhìn nhanh hình dáng phân phối (chuông, lệch, đa đỉnh).
- **Lưu ý**
  - **Binning Bias:** Việc chọn độ rộng cột (`bin_width`) sai có thể hiểu sai.
  - Không bao giờ vẽ 1 biểu đồ Histogram duy nhất. Hãy vẽ 3 cái với bins = 10, 50, 100.
- **Ví dụ:** Dữ liệu tuổi khách hàng.
  - Nếu chọn bin = 20 năm: Thấy có 1 cột cao vút \rightarrow Kết luận: "Khách hàng phân bố đều".
  - Nếu chọn bin = 5 năm: Thấy có 2 đỉnh tách biệt (nhóm 20-25 tuổi và nhóm 50-60 tuổi). Hóa ra bạn bị mất nhóm khách hàng trung niên (30-40).

**(2). CDF (Cumulative Distribution Function)** - Hàm phân phối tích lũy

- **Định nghĩa:** Tại một giá trị x, CDF cho biết "Có bao nhiêu phần trăm dữ liệu nhỏ hơn hoặc bằng x?". Trục tung (y) luôn chạy từ 0 đến 1 (hoặc 0% đến 100%).
- Tip: nên dùng CDF thay vì Histogram để so sánh dữ liệu hoặc đọc phân vị (Percentile) vì nó không bị nhiễu do chia cột.
- **Cách đọc :**
  - Trục tung (y): Luôn là Tỷ lệ % (0 đến 1).
  - Trục hoành (x): Giá trị biến số (Ví dụ: Doanh thu).
  - **Ví dụ:** Bạn nhìn điểm (x=500k, y=0.8). Nghĩa là: "80% đơn hàng có giá trị thấp hơn hoặc bằng 500k".
  - **So sánh 2 đường CDF:**
    Nếu đường CDF của nhóm A luôn nằm **bên dưới** đường nhóm B \rightarrow Nhóm A có giá trị lớn hơn nhóm B về mặt thống kê (Stochastic Dominance).

Ví dụ: So sánh Lương Nam và Nữ.

- Trục tung: Tỷ lệ % người. Trục hoành: Mức lương.
- Bạn chọn điểm y = 0.5 (50% dân số - chính là Median).
- Dóng sang đường CDF của Nữ \rightarrow chạm mức lương 10 triệu.
- Dóng sang đường CDF của Nam \rightarrow chạm mức lương 15 triệu.

\rightarrow Kết luận ngay: Ở mức trung vị, Nam lương cao hơn Nữ.

Nếu đường CDF của Nữ luôn nằm **bên trái** đường của Nam \rightarrow Nữ lương thấp hơn Nam ở mọi phân khúc (từ nhân viên đến sếp)

**(3). PMF (Probability Mass Function)** - Hàm khối xác suất
**Định nghĩa:** Biểu diễn xác suất xuất hiện của từng giá trị cụ thể.
**Lưu ý:** Chỉ dùng cho **biến rời rạc** có ít giá trị ( số lượng con, số lần khiếu nại ,..). Khác với Histogram (vẽ các cột dính liền thể hiện sự **liên tục**) là PMF không gộp nhóm (vẽ các vạch tách rời (thể hiện sự **rời rạc**).
**Ví dụ:** "Số con trong gia đình" (1, 2, 3, 4 con).

- Histogram có thể gộp "1 con" và "2 con" vào chung 1 cột nếu bạn không để ý.
- PMF sẽ vẽ tách biệt: Xác suất nhà 1 con là 20%, 2 con là 50%. Rất rõ ràng.

**(4). Q-Q Plot (Quantile-Quantile Plot):** Kiểm tra chuẩn.

- **Định nghĩa:** Biểu đồ so sánh phân vị của dữ liệu thực tế với phân vị của Phân phối Chuẩn lý thuyết.
- **Ý nghĩa:** Dùng để kiểm tra nhanh xem dữ liệu có "Chuẩn" (Normal) hay không. Nhiều thuật toán (như Linear Regression, t-test) chỉ hoạt động tốt nếu dữ liệu tuân theo phân phối chuẩn.
- **Cách đọc:**
  - Các điểm nằm thẳng tắp trên đường chéo 45 độ \rightarrow **Phân phối Chuẩn**.
  - Cong hình chữ U hoặc S: Dữ liệu bị lệch (Skewed).
  - Lệch ở 2 đầu mút hoặc các điểm bị cong hình chữ S: Có "Đuôi dày" (Fat tails) - nhiều giá trị ngoại lai hơn bình thường. \rightarrow **Không chuẩn** (có đuôi dày hoặc bị lệch).

**Ví dụ:** Trước khi chạy Linear Regression, cần vẽ Q-Q Plot cho phần dư (residuals). Nếu thấy đường cong queo, bạn biết ngay mô hình đang có vấn đề, dự báo sẽ không đáng tin cậy.

**d) Các chỉ số hình dáng dữ liệu:** để đo lường sự méo mó của dữ liệu .

**(1). Skewness (Độ lệch) - S**

- *Hình dáng:* Đỉnh lệch trái, **đuôi dài về bên phải**.

- **S = 0 :** Đối xứng hoàn hảo (Phân phối chuẩn).
- **S > 0 (Lệch phải / Positive):** Đuôi dài bên phải
  - Mean > Median - Giá trị trung bình ( Mean ) bị kéo cao hơn thực tế ( Median )
  - *Ví dụ:* **Thu nhập**. Đa số mọi người thu nhập thấp (đỉnh nằm trái), nhưng có vài tỷ phú (đuôi kéo dài sang phải).
  - **Xử lý**: dùng sqrt(x)- độ lệch nhẹ hay log transform- độ lệch phải rất lớn để kéo nó về chuẩn.
- **S < 0(Lệch trái / Negative):** Đuôi dài bên trái.
  - Mean < Median - Giá trị trung bình thấp hơn thực tế.
  - *Ví dụ:* **Tuổi thọ**. Hầu hết sống lâu, vài người mất sớm.
  - *Xử lý:* Dùng hàm x^2 hoặc exp(x).

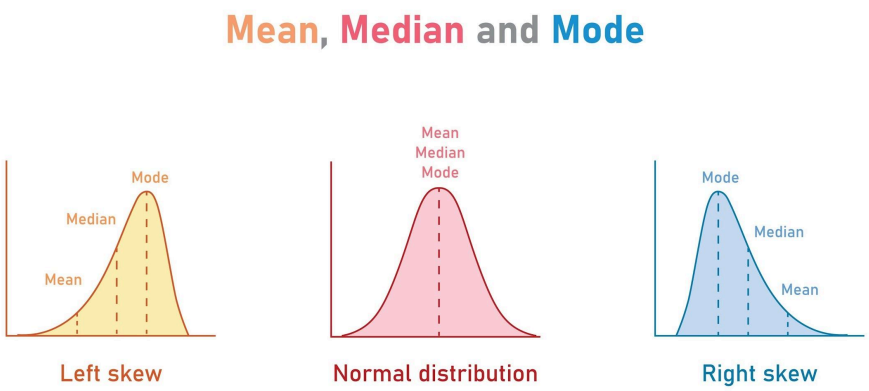


**(2). Kurtosis (Độ nhọn/ độ dày của đuôi ) - K**

- **Định nghĩa:** Đo lường mức độ "béo" của cái đuôi phân phối (Fat tails).
  - **K = 3 :** Chuẩn (Normal Distribution).
  - **K > 3 (Leptokurtic):** Đỉnh nhọn, đuôi dày.
    - *Nguy hiểm:* Dữ liệu tập trung nhiều ở trung tâm, nhưng hễ lệch là lệch rất xa (Outliers cực mạnh). Đây là đặc tính của dữ liệu tài chính (Crypto, Chứng khoán).
  - **K < 3 (Platykurtic):** Đỉnh thấp, vai rộng.
    - *Ý nghĩa:* Dữ liệu tản mát đều, ít giá trị cực đoan. Ví dụ: Chiều cao

của các vận động viên chuyên nghiệp (khá đồng đều).

- **Ý nghĩa:** Liên quan đến rủi ro của các sự kiện hiếm (Black Swan)
- **Ví dụ (Tài chính):**
    - Phân phối chuẩn (Normal) có Kurtosis = 3.
    - Cổ phiếu A có Kurtosis = 10 (Leptokurtic - Đuôi rất dày).

$\rightarrow$ Điều này nghĩa là cổ phiếu A có xác suất rớt giá thảm hại (hoặc tăng giá điên cuồng) cao hơn nhiều so với dự đoán của mô hình chuẩn. Nhà đầu tư cần cực kỳ cẩn thận.

### 3.2. Biến Phân loại (Categorical Variables)

Trước khi bắt đầu, hãy phân biệt rõ 2 loại biến phân loại, vì cách xử lý chúng khác nhau hoàn toàn:

- **Biến Định danh (Nominal):** Không có thứ tự. *Ví dụ: Màu sắc (Đỏ, Xanh), Tỉnh thành (Hà Nội, Huế).*
- **Biến Thứ bậc (Ordinal):** Có thứ tự logic. *Ví dụ: Size áo (S, M, L), Trình độ học vấn (Cấp 3, Đại học, Thạc sĩ).*

#### a) Tần suất và tỉ lệ:

- Định nghĩa : là bảng đếm số lần xuất hiện (`Count`) và tính phần trăm (`%`) của từng nhóm giá trị trong cột.
- Ý nghĩa : hiểu độ lớn và tỉ trọng của dữ liệu
    - **Count (Số lượng):** Cho biết độ lớn của mẫu. (Tin cậy hay không?)
    - **Percent (%):** Cho biết tỷ trọng và đánh giá sự phân bố. (Quan trọng hay không?)
    - **Cumulative % (Phần trăm tích lũy):** Cho biết độ tập trung. (Dùng cho quy tắc Pareto 80/20).
- Ví dụ: Phân tích tỉ lệ rời khách hàng  hủy đơn hàng.

| **Lý do (Category)** | **Số lượng (Count)** | **Tỷ lệ (%)** | **Tích lũy (Cum. %)** |
|---|---|---|---|
| Đổi ý | 500 | 50% | 50% |
| Phí ship cao | 300 | 30% | 80% |

| | | | |
|---|---|---|---|
| Tìm thấy chỗ rẻ hơn | 150 | 15% | 95% |
| Khác | 50 | 5% | 100% |

**Insight:** Nhìn vào cột **Tích lũy**: Chỉ cần giải quyết 2 lý do đầu ("Đổi ý" và "Phí ship") là bạn đã giải quyết được **80%** vấn đề của công ty. Đây chính là sức mạnh của Frequency Table chuẩn.

- **Lưu ý : Xử lý Biến Nhị phân (Binary Variables - 0/1)**.
    - **Mẹo:** Với biến chỉ có 0 và 1 (Ví dụ: `Is_Fraud`), thì **Mean chính là Tỷ lệ (Proportion)**.
    - **Ví dụ:** Cột `Gian_lận` (0: ko, 1: có). `Mean(Gian_lận) = 0.05` -> Nghĩa là có 5% gian lận. Cách này nhanh hơn nhiều so với việc ngồi đếm Count rồi chia tổng.

b) Trực quan hóa - biểu thanh ( bar chart):

**(1). Cách chọn chiều biểu đồ:**

- **Bar Chart Dọc (Column Chart):** Dùng khi số lượng nhóm ít (< 10) và tên nhóm ngắn (Ví dụ: Các ngày trong tuần, Giới tính).
- **Bar Chart Ngang (Horizontal Bar Chart):**
    - *Bắt buộc dùng khi:* Tên nhóm dài (Ví dụ: Tên trường Đại học, Tên Tỉnh thành).
    - *Tại sao:* Nếu vẽ dọc, chữ bên dưới sẽ bị nghiêng 45 độ hoặc chồng lên nhau, người xem phải vẹo cổ để đọc. Vẽ ngang giúp nhãn (label) hiển thị rõ ràng, chuyên nghiệp.

**(2). Quy tắc sắp xếp biến dữ liệu - *Cực kỳ quan trọng*:**

Đây là lỗi phổ biến nhất của người mới.

- **Với Biến Định danh (Nominal - Không thứ tự):**
    - *Quy tắc:* Sắp xếp theo **Tần suất giảm dần** (Cao nhất ở trên/trái, thấp nhất ở dưới/phải).
    - *Tại sao:* Mắt người đọc từ trái sang phải. Hãy đưa thông tin quan trọng nhất (nhóm đông nhất) lên đầu (Pareto). *Tuyệt đối không sắp xếp theo bảng chữ cái A-Z (trừ khi làm từ điển).*
- **Với Biến Thứ bậc (Ordinal - Có thứ tự):**
    - *Quy tắc:* Sắp xếp theo **Thứ tự logic vốn có**.
    - *Ví dụ:* Sơ cấp -> Trung cấp -> Cao cấp. Dù nhóm Trung cấp có cao vọt lên thì nó vẫn phải nằm ở giữa Sơ cấp và Cao cấp. Nếu đảo lộn, người xem sẽ mất cảm giác về sự

tiến triển.

### c) Số lượng nhóm duy nhất - Cardinality: xử lí sự rời rạc của dữ liệu

**(1). Định nghĩa & Vấn đề**

- **Định nghĩa:** Cardinality là số lượng giá trị duy nhất (unique levels) trong một biến phân loại.
- Phân loại:
  - **Ít nhóm - Low Cardinality:** Giới tính (2), Mùa (4). -> *Dễ xử lý (One-Hot Encoding).*
  - **Nhiều nhóm - High Cardinality:** Khi một biến có quá nhiều giá trị duy nhất.-> *Ác mộng của mô hình. Ví dụ:* Mã ZIP (2000 mã), Tên Đường (5000 tên).
- **Hậu quả của nhiều nhóm:**
  - **Nát biểu đồ:** Vẽ Bar Chart với 2000 thanh là vô nghĩa.
  - **Phình to dữ liệu:** Khi đưa vào mô hình AI,  Nếu bạn dùng kỹ thuật chuẩn là **One-Hot Encoding** (chuyển thành các cột 0/1) cho cột Zipcode (2000 mã), bộ dữ liệu của bạn sẽ bị phình to thêm 2000 cột nữa.ta thường dùng kỹ thuật *One-Hot Encoding* (biến mỗi nhóm thành 1 cột).

-> Máy tính chạy chậm (hoặc treo).

-> Mô hình bị Overfitting (Học vẹt từng mã bưu điện thay vì học quy luật vùng miền).

**(2). Kỹ thuật xử lý (Feature Engineering)**

Dựa vào EDA, ta áp dụng chiến thuật **"Gom nhóm" (Lumping/Binning)**:

**Cách 1: Binning (** Gom các nhóm nhỏ lại).

**a. Kỹ thuật "Top N + Others" (Pareto Binning)**

- **Cách làm:** Giữ lại Top 10 hoặc 20 nhóm xuất hiện nhiều nhất. Tất cả các nhóm còn lại gộp chung thành một nhóm mới tên là **"Others"**.
- **Ví dụ:** Dữ liệu quốc tịch khách du lịch.
  - Giữ: Mỹ, Trung Quốc, Hàn Quốc, Nhật Bản (chiếm 80% khách).
  - Gộp: Lào, Campuchia, Anh, Pháp... thành "Others".
- **Lợi ích:** Giảm Cardinality từ 200 xuống còn 5. Thông tin quan trọng vẫn được giữ nguyên.

**b. Gom nhóm theo nghiệp vụ (Domain-based Binning)**

- **Cách làm:** Dùng kiến thức thực tế để gom nhóm.
- **Ví dụ:** Cột Quốc gia (200 nước).
  - Gom thành: Châu Á, Châu Âu, Châu Mỹ, Châu Phi... (Giảm xuống còn 5 nhóm).
- **Ví dụ:** Cột Mã Zipcode.

- Gom theo đầu số: Các mã bắt đầu bằng 100 là Hà Nội, 700 là TP.HCM.

**Cách 2: Frequency Encoding (Mã hóa tần suất)**

- *Ý tưởng:* Thay thế tên nhóm bằng số lượng xuất hiện của nó.
- *Ví dụ:* Zipcode "10000" xuất hiện 500 lần -> Thay chữ "10000" bằng số 500.

**Cách 3: Target Encoding (Mean Encoding) - *nâng cao***

- *Ý tưởng:* Thay thế tên nhóm bằng "Giá trị trung bình của biến mục tiêu ($y$)" tại nhóm đó.
- *Ví dụ:* **:** Dự đoán giá nhà ($y$). Cột Phường có giá trị "Bến Nghé".
  - Bước 1: Tính trung bình giá nhà của tất cả các căn ở phường Bến Nghé = 20 tỷ.
  - Bước 2: Thay chữ "Bến Nghé" bằng con số **20**.
- **Ưu điểm:** Giữ được thông tin giá trị mà không làm tăng số lượng cột.
- **Rủi ro (Data Leakage):** Bạn đang dùng thông tin của $y$ (câu trả lời) để tạo ra biến đầu vào ($x$). Nếu không cẩn thận (phải tính trên tập Train riêng, không tính trên tập Test), mô hình sẽ học vẹt và thất bại khi ra thực tế.

**d) Kiểm tra tính cân bằng:** Phát hiện các biến rác

**Vấn đề "Sự thống trị" của dữ liệu: (Dominance/Imbalance):**

- **Định nghĩa:** Khi một giá trị (Level) chiếm tỷ lệ áp đảo (thường > 95% hoặc > 99%).
- Ý nghĩa: Trong Machine Learning, một biến muốn có giá trị dự báo thì nó phải biết "phân biệt" các đối tượng. Nếu giá trị nào cũng giống nhau, nó không cung cấp thông tin (Information Gain = 0).
- **Ví dụ:** Trong dữ liệu phát hiện gian lận (Fraud Detection).
  - Cột Is_Human (Là người hay Bot).
  - Giá trị "Yes" (Là người) chiếm 99.9%. Giá trị "No" (Bot) chiếm 0.1%.
- **Hậu quả:**
  - **Mô hình "lười biếng":** Mô hình học máy sẽ coi biến này là vô dụng vì nó gần như là hằng số.
  - **Kỹ thuật Splitting:** Khi chia tập Train/Test ngẫu nhiên, có khả năng toàn bộ nhóm 0.1% kia sẽ rơi hết vào tập Train, tập Test không còn ai $\rightarrow$ Không đánh giá được mô hình.

**(2). Giải pháp:**

- Nếu tỷ lệ > 99%: Cân nhắc **XÓA** cột này (nếu không phải là cột Target).
- Nếu là cột Target: Phải dùng kỹ thuật **Resampling** (SMOTE, Undersampling) để cân bằng lại dữ liệu trước khi train.

## Phần 4: Phân tích 2 biến và đa biến

*Tìm kiếm các mối quan hệ (Relationships) và tương tác (Interactions).*

### 4.1. Số vs Số (Numeric vs Numeric)

**(1) Scatterplot- biểu đồ tán xạ**:

Đây là bước bắt buộc khi so sánh 2 biến số . Đừng bao giờ tính hệ số tương quan (Correlation) trước khi vẽ hình.

**a) Định nghĩa**

- **Định nghĩa:** Scatterplot vẽ mỗi điểm dữ liệu lên mặt phẳng tọa độ (x, y). Nó giúp tìm ra **Hình dáng (Shape)** của mối quan hệ và trả lời: Mối quan hệ này là đường thẳng (Tuyến tính) hay đường cong (Phi  tuyến tính).
- Các hình dạng phổ biến:
    - **Tuyến tính (Linear):** Các điểm xếp thành đường chéo thẳng tắp.
        - *Ví dụ:* Diện tích nhà tăng $\rightarrow$ Giá nhà tăng.
    - **Phi tuyến (Non-linear / Curvilinear):** Các điểm xếp thành đường cong, hình chữ U, hoặc hình S.
        - *Ví dụ:* Nhiệt độ và Doanh số bán áo khoác. Khi trời lạnh (10 độ), bán chạy. Khi trời quá lạnh (-10 độ), người ta ở nhà, bán ế. Khi trời nóng (30 độ), không ai mua. $\rightarrow$ Hình dáng là đường cong Parabol ngược.
    - **Đám mây vô định (No correlation):** Các điểm rải rác như bầu trời sao, không theo quy luật nào. *Ví dụ:* Số đo giày và Chỉ số IQ

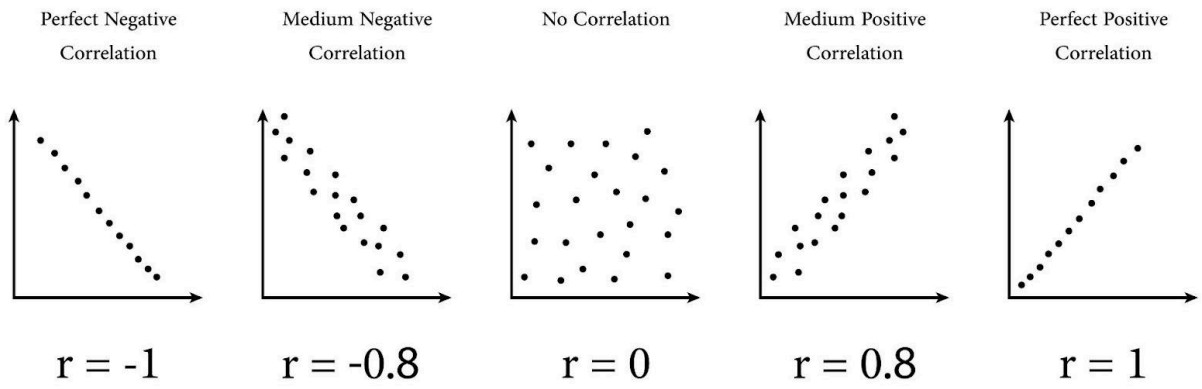


**b) Kỹ thuật "Đường cong mềm mại" (LOESS/ LOWESS)**

- **Vấn đề:** Khi dữ liệu quá nhiều nhiễu (các điểm nhảy lung tung), mắt thường khó thấy xu hướng chính. LOESS (Locally Estimated Scatterplot Smoothing) là thuật toán vẽ một "đường cong mềm mại" đi xuyên qua đám mây điểm để chỉ ra xu hướng trung tâm Ta không biết xu hướng chính là đi lên hay đi ngang.
- **Giải pháp LOESS (Locally Estimated Scatterplot Smoothing):**
    - Đây là thuật toán vẽ một "đường trung bình trượt" uốn lượn đi xuyên qua đám mây dữ liệu. Nó không bị ép phải thẳng như đường Hồi quy tuyến tính.
- **Ví dụ:** Phân tích hiệu quả chạy quảng cáo.
    - *Trục X:* Số tiền chi cho quảng cáo. *Trục Y:* Doanh thu.
    - *Dữ liệu thô:* Rất nhiễu.
    - *Đường LOESS:* Sẽ cho thấy hình dáng chữ **"S"**.
        - Đoạn đầu: Chi ít tiền $\rightarrow$ Doanh thu tăng chậm.
        - Đoạn giữa: Chi đủ tiền $\rightarrow$ Doanh thu bùng nổ (dốc đứng).
        - Đoạn cuối: Chi quá nhiều $\rightarrow$ Bão hòa, doanh thu đi ngang (đường nằm phẳng).
    - *Insight:* Nhìn đường LOESS, Sếp biết ngay điểm "bão hòa" để dừng chi tiền.

## (2) Các cách giải quyết vấn đề “Quá dày đặc” (overplotting)

Khi bạn có hàng trăm nghìn dòng dữ liệu- bigData, Scatterplot sẽ biến thành một "cục mực đen xì". Bạn không biết ở chỗ đen đó có 1,000 điểm hay 1 triệu điểm. Mất khả nnawng nhìn thất mật độ - đây gọi là **Overplotting**.

**a) Alpha Blending (Độ trong suốt)**

- **Khái niệm:** Thay vì vẽ điểm màu đen đặc (Solid), ta vẽ điểm mờ (Transparent).
    - alpha = 0.1 nghĩa là điểm đó trong suốt 90%. Phải có **10 điểm chồng lên nhau** tại đúng vị trí đó thì nó mới hiện ra màu đen đậm.
- **Tình huống:** Bản đồ các chuyến xe Grab buổi sáng.
    - *Không dùng Alpha:* Cả thành phố bị tô đen. Bạn tưởng chỗ nào cũng đông khách.
    - *Dùng Alpha:*
        - Các con đường nhỏ: Màu xám nhạt (ít xe).
        - Ngã tư lớn: Màu đen đậm (kẹt xe).
    - *Tác dụng:* Giúp bạn nhìn xuyên qua dữ liệu để thấy **vùng lõi mật độ**.

**b) Jittering (Làm nhiễu ngẫu nhiên) - Quan trọng cho dữ liệu rời rạc**

**Khái niệm:** Thêm một chút nhiễu (noise) ngẫu nhiên vào tọa độ của các điểm để tách chúng ra. Kỹ thuật này bắt buộc dùng khi dữ liệu bị **rời rạc hóa** (discretized)

Ví dụ:

- **Vấn đề:** Dữ liệu số nguyên hoặc thang đo (1-5 sao).
    - Ví dụ: Khảo sát Thâm niên (1, 2, 3 năm) và Đánh giá (1, 2, 3, 4, 5 sao).
    - Có 1000 nhân viên, nhưng trên biểu đồ bạn chỉ thấy **đúng 15 chấm** (vì 100 ông "2 năm - 5 sao" đè lên nhau tại đúng tọa độ (2, 5)).
- **Giải pháp Jittering:**
    - Máy tính sẽ cộng thêm một chút xíu "độ lệch" ngẫu nhiên vào tọa độ.
    - Ông A (2, 5) $\rightarrow$ (2.01, 4.99).
    - Ông B (2, 5) $\rightarrow$ (1.99, 5.02).
- **Kết quả:** Từ "1 chấm", nó bung ra thành một "đám mây" nhỏ xung quanh điểm (2, 5).
    - Nếu đám mây đó to và đen $\rightarrow$ Rất nhiều người ở nhóm này.
    - Nếu đám mây lưa thưa $\rightarrow$ Ít người.

*[Hình dung: Giống như bạn rắc cát lên bàn cờ thay vì xếp chồng các quân cờ lên nhau]*

**c) Hexbin Plot (Biểu đồ tổ ong) - Giải pháp cho Big Data**

- **Lý thuyết:** Khi dữ liệu lên tới hàng triệu dòng, Hexbin chia mặt phẳng thành các hình lục giác (tổ ong). Màu sắc của ô lục giác thể hiện số lượng điểm rơi vào ô đó
- **Cách làm:**
    - Chia mặt phẳng thành lưới các hình lục giác (như tổ ong).
    - Đếm số điểm rơi vào mỗi ô lục giác.

    - Tô màu ô đó theo số lượng: Ít thì màu nhạt (Xanh), Nhiều thì màu nóng (Đỏ).
- **Ví dụ:** Phân tích mối quan hệ giữa *Giá vé* và *Khoảng cách bay* của 10 triệu chuyến bay.
  - Scatterplot thường: Treo máy hoặc đen kịt.
  - Hexbin Plot: Bạn sẽ thấy các "ô đậm màu" ở khoảng cách ngắn giá rẻ, và các "ô nhạt màu" ở khoảng cách xa giá đắt. Nó giống như bản đồ nhiệt (Heatmap) dành cho Scatterplot.

### (3) Correlation Matrix - ma trận tương quan

Đây là công cụ để đo lường độ mạnh/yếu của mối quan hệ bằng con số cụ thể. Con số đó chạy từ **-1** (Nghịch biến hoàn toàn) đến **+1** (Đồng biến hoàn toàn). (từ -1 đến 1).

a) Pearson Correlation (r) - "Tương quan tuyến tính - Vị giám khảo khó tính"

- Lưu ý: Chỉ dùng khi mối quan hệ là đường thẳng (Linear) và dữ liệu không có quá nhiều Outlier
- **Đặc điểm:** Chỉ đo lường mối quan hệ **Tuyến tính (Đường thẳng)**.
- **Công thức:** Đo mức độ biến thiên cùng nhau của 2 biến.
- **Nhược điểm chết người:** Cực kỳ nhạy cảm với Outlier.
- **Ví dụ:**
  - 10 người bình thường: Lương tăng $\rightarrow$ Chi tiêu tăng. (Tương quan tốt).
  - Thêm 1 ông "tằn tiện": Lương 1 tỷ/tháng nhưng chỉ tiêu 1 triệu/tháng.
  - $\rightarrow$ Hệ số Pearson sẽ tụt dốc không phanh, báo rằng "Lương và Chi tiêu ít liên quan", dù thực tế 10 người kia vẫn liên quan chặt chẽ.

b) Spearman Correlation ($\rho$): Biểu đồ tương quan hạng  - "Vị giám khảo linh hoạt"

- **Lý thuyết:** Dựa trên thứ hạng (rank) thay vì giá trị thực. Dùng khi dữ liệu có **Outlier** hoặc quan hệ **Phi tuyến** (Miễn là X tăng thì Y tăng, không cần tăng theo đường thẳng
- **Đặc điểm:** Dựa trên **Thứ hạng (Rank)** chứ không phải giá trị thô.
  - Nó không quan tâm bạn lương 1 tỷ hay 100 triệu, nó chỉ quan tâm bạn là "Người giàu nhất nhóm" (Rank 1).
- **Ưu điểm:**
  - **Chống lại Outlier:** Ông tằn tiện lương 1 tỷ chỉ đơn giản là Rank 1 về lương, Rank chót về chi tiêu. Nó không phá hỏng cấu trúc của cả nhóm.
  - **Bắt được quan hệ Phi tuyến (Monotonic):** Miễn là X tăng thì Y tăng (dù tăng theo đường cong), Spearman vẫn cho điểm cao (gần +1).

- **Quy tắc:** Nếu Pearson và Spearman chênh lệch nhau quá nhiều (Ví dụ: Pearson = 0.4, Spearman = 0.9) $\rightarrow$ Dữ liệu chắc chắn có **Outlier lớn** hoặc quan hệ **Phi tuyến**. Hãy tin Spearman.
- Ví dụ:
    - **Tình huống (Outlier):** Mối quan hệ giữa *Số năm kinh nghiệm* và *Lương*.
        - Dữ liệu: 10 nhân viên lương 10tr-20tr. Có 1 ông Sếp lương 1 tỷ.
        - *Pearson:* Sẽ bị ông Sếp kéo lệch, cho ra hệ số tương quan rất cao (ảo).
        - *Spearman:* Nó coi ông Sếp là "người lương cao nhất" (Rank 1), ông phó là Rank 2... Khoảng cách 1 tỷ hay 20tr không còn quan trọng. Hệ số Spearman phản ánh đúng mối quan hệ của đa số nhân viên.
    - **Tình huống (Phi tuyến):** Mối quan hệ *Diện tích* và *Giá nhà*.
        - Giá nhà có thể tăng theo cấp số nhân với diện tích (Biệt thự siêu to giá siêu đắt).
        - Spearman bắt được mối quan hệ này tốt hơn Pearson.

c) Heatmap (Biểu đồ nhiệt tương quan)

- **Mục tiêu:** Khi bạn có 20 biến số, bạn không thể ngồi đọc 190 cặp số tương quan ($20 \times 19 / 2$).
- **Cách làm:** Vẽ một ma trận màu.
    - Màu Đỏ đậm: Tương quan dương mạnh (+1).
    - Màu Xanh đậm: Tương quan âm mạnh (-1).
    - Màu Trắng/Nhạt: Không tương quan (0).
- **Vấn đề Đa cộng tuyến (Multicollinearity):**
    - Nếu trong Heatmap bạn thấy 2 biến đầu vào (ví dụ: Diện tích nhà và Số phòng ngủ) có màu Đỏ chót (tương quan 0.95).
    - **Hành động:** Cảnh báo nguy hiểm! Hai biến này cung cấp thông tin y hệt nhau. Khi chạy mô hình, chúng sẽ gây nhiễu cho nhau. Nên loại bỏ bớt 1 biến.

### 4.2. Biến Số vs Biến Phân loại

Mục tiêu: So sánh sự khác biệt về hành vi (Biến số) giữa các nhóm đối tượng (Biến phân loại).

#### (1). Biểu đồ Boxplot nhiều nhóm

Trước khi làm gì phức tạp, hãy xếp hàng các nhóm ra và so chiều cao .

Cách đọc biểu đồ:  Đừng chỉ nhìn vào một cái hộp. Hãy nhìn **tương quan** giữa các hộp:

1. **So sánh Median (Vạch giữa hộp):** Vạch của nhóm A có cao hơn nhóm B không? -> Cho biết mức trung bình (đại diện) của nhóm nào tốt hơn.

2. **So sánh IQR (Chiều cao hộp):** Hộp nào dài hơn? -> Nhóm đó có nội bộ phức tạp hơn, biến động nhiều hơn.
3. **So sánh Sự chồng lấn (Overlap):**
    - Nếu 2 cái hộp nằm lệch hẳn nhau (không chạm nhau) -> Sự khác biệt rất rõ ràng.
    - Nếu 2 cái hộp chồng lên nhau (vạch Median của nhóm này nằm trong hộp của nhóm kia) -> Sự khác biệt có thể chỉ là ngẫu nhiên, không đáng kể.

Ví dụ: So sánh **Lương (Số)** giữa 3 phòng ban: **IT, HR, Sales (Phân loại)**.

- **Hình ảnh Boxplot:**
    - **Hộp IT:** Nằm tít trên cao, hộp ngắn. -> Lương cao và đồng đều (ai cũng cao).
    - **Hộp HR:** Nằm thấp, hộp ngắn. -> Lương thấp và ổn định.
    - **Hộp Sales:** Hộp rất dài. Vạch Median nằm giữa IT và HR, nhưng cái "râu" (whiskers) kéo dài từ rất thấp đến rất cao.
    - **Insight:** Phòng Sales là nơi phân hóa giàu nghèo khốc liệt nhất. Có người lương thấp hơn cả HR, nhưng có "Best Seller" lương cao hơn cả IT.

### (2) Biểu đồ Violin Plot

Boxplot rất tuyệt, nhưng nó hay "nói dối" về hình dáng dữ liệu. Violin Plot sinh ra để vạch trần lời nói dối đó.

**Vấn đề của Boxplot (Sự che giấu)**

Boxplot chỉ hiện 1 khối chữ nhật. Nó giả định dữ liệu tụ tập ở giữa (Unimodal).

- **Ví dụ :** Điểm thi của lớp học.
    - Nhóm 1: Học sinh giỏi và dốt bằng nhau. (Giỏi 10 điểm, Dốt 0 điểm). -> Trung bình là 5.
    - Nhóm 2: Tất cả học sinh đều học lực trung bình. (Toàn 5 điểm). -> Trung bình là 5.
    - **Boxplot:** Sẽ vẽ ra 2 cái hộp **giống hệt nhau** (Median = 5). Bạn tưởng 2 lớp học này giống nhau. Sai lầm!

**Giải pháp Violin Plot (Kết hợp Density)**

- **Hình dáng:** Giống cây đàn Violin hoặc cái lá. Chỗ nào "bụng phình to" là chỗ dữ liệu tập trung nhiều.
- **Áp dụng tình huống trên:**
    - Nhóm 2 (Học đều): Violin phình to ở giữa (số 5). Hình quả trám.
    - Nhóm 1 (Phân cực): Violin thắt eo ở giữa (số 5 không có ai), nhưng phình to ở 2 đầu (số 0 và số 10). Hình củ lạc hoặc số 8.
- **Kết luận:** Khi thấy Violin có **2 bụng (Bimodal)**, bạn biết ngay nhóm đó đang bị phân cực, cần tách ra xử lý riêng.

### (3). Biểu đồ Ridgeline plot

Khi có quá nhiều nhóm (ví dụ: 12 tháng, 63 tỉnh thành), vẽ Boxplot hay Violin xếp hàng ngang sẽ rất rối mắt. Ridgeline giải quyết vấn đề này bằng cách xếp chồng theo chiều dọc 3D.

**Cách vẽ:** Vẽ nhiều biểu đồ phân phối (Density Plot) của từng nhóm, rồi xếp chúng hơi đè lên nhau (như những dãy núi trùng điệp).

Ví dụ : Phân tích **Nhiệt độ (Số)** theo **12 Tháng (Phân loại)**.

- **Boxplot:** 12 cái hộp đứng cạnh nhau, nhìn mỏi mắt.
- **Ridgeline:** Bạn thấy 12 "ngọn núi" chạy từ trên xuống dưới.
    - Tháng 1, 2: Núi nằm bên trái (Lạnh).
    - Tháng 6, 7: Núi dịch chuyển sang phải (Nóng).
    - Tháng 12: Núi lại trôi về bên trái.
- **Ưu điểm:** Cực kỳ tốt để nhìn thấy **Xu hướng (Trend)** dịch chuyển giữa các nhóm thứ tự.

### (4). ANOVA - phân tích phương sai

Biểu đồ chỉ cho ta "cảm giác". ANOVA cho ta "con số khẳng định".

Nguyên lý "Tín hiệu trên Nhiễu": ANOVA so sánh 2 loại phương sai:

1. **Variance Between Groups (Sự khác biệt GIỮA các nhóm):** Khoảng cách giữa các Median của nhóm A, B, C. (Đây là Tín Hiệu - Signal).
2. **Variance Within Groups (Sự biến động TRONG NỘI BỘ nhóm):** Độ rộng của từng cái hộp. (Đây là Nhiễu - Noise).

- **Công thức tư duy:**
  $$F = \frac{\text{Sự khác biệt giữa các nhóm (Signal)}}{\text{Sự lộn xộn trong nội bộ (Noise)}}$$
- **Quy tắc:**
    - Nếu $F$ lớn (Signal >> Noise): Sự khác biệt là **có ý nghĩa thống kê**. (Các nhóm thực sự khác nhau).
    - Nếu $F$ nhỏ (Signal $\approx$ Noise): Sự khác biệt bạn thấy chỉ là ngẫu nhiên. (Các nhóm bản chất giống nhau).

**Ví dụ:** So sánh chiều cao của: Đội bóng rổ (Nhóm A) và Đội bóng đá (Nhóm B).

- **Tình huống 1:** Đội rổ toàn người 1m9-2m. Đội đá toàn 1m7-1m75.
    - Khác biệt giữa 2 đội (Signal) rất lớn. Nội bộ từng đội (Noise) chênh lệch ít.
    - -> **ANOVA $F$ cao**. Kết luận: Đội rổ cao hơn Đội đá thật sự.
- **Tình huống 2:** So sánh Lớp 1A và Lớp 1B.

    - Lớp 1A trung bình 1m2, nhưng có bé 1m, có bé 1m4 (Nội bộ lộn xộn - Noise lớn).
    - Lớp 1B trung bình 1m25, nội bộ cũng lộn xộn.
    - -> Chênh lệch trung bình (1m2 vs 1m25) quá nhỏ so với sự lộn xộn nội bộ.
    - -> **ANOVA $F$ thấp**. Kết luận: Không dám chắc Lớp 1B cao hơn, có thể do bốc thăm ngẫu nhiên thôi.

(5) Faceting ( tách hình ) - chia để trị

Đây là kỹ thuật tốt nhất để xử lý dữ liệu phức tạp (3-4 biến cùng lúc).

**Vấn đề của biểu đồ đơn:** Khi muốn xem mối quan hệ giữa **Doanh thu** và **Tuổi**, nhưng muốn phân tách cho cả **Giới tính** và **Vùng miền**.

- Nếu vẽ tất cả vào 1 hình Scatterplot: Bạn phải dùng màu sắc (cho Giới tính), hình dáng điểm (cho Vùng miền). -> Kết quả: Một nồi lẩu thập cẩm rối rắm. Không ai đọc được.

**Giải pháp Faceting:** Tách biểu đồ to thành nhiều biểu đồ con (như các khung tranh nhỏ), mỗi biểu đồ con hiển thị một nhóm.
**Ví dụ :** Phân tích xu hướng mua hàng (Doanh thu vs Tuổi) của Nam/Nữ ở 3 miền Bắc/Trung/Nam.

- **Cách làm (Faceting):**
    - Tạo một lưới biểu đồ $2 \times 3$:
        - Hàng 1: Nam (Bắc - Trung - Nam).
        - Hàng 2: Nữ (Bắc - Trung - Nam).
    - Mỗi ô vẽ một đường xu hướng (Trendline) riêng.
- **Insight phát hiện được:**
    - "Nữ ở Miền Bắc mua nhiều khi trẻ, nhưng Nữ ở Miền Nam lại mua nhiều khi trung niên".
    - Nếu gộp chung lại, hai xu hướng này triệt tiêu nhau, bạn sẽ thấy đường đi ngang (không có xu hướng). Faceting giúp **bóc tách các tương tác ẩn** này.

### 4.3. Đa biến (Multivariate - >3 biến)

Mục tiêu: Tìm hiểu cấu trúc phức tạp, sự tương tác giữa nhiều biến cùng lúc và giảm bớt độ phức tạp để dễ nhìn hơn.

(1) Mosaic plot - bản đồ diện tích

Khi bạn muốn so sánh 2 biến phân loại (Categorical vs Categorical) mà Bar Chart trở nên quá rối, Mosaic Plot là giải pháp để trực quan hóa .

**Khái niệm:** Là biểu đồ ô vuông, trong đó **diện tích** của mỗi ô tỷ lệ thuận với số lượng mẫu.

- **Tư duy:** Hãy tưởng tượng nó như một hình vuông được cắt làm nhiều phần.
    - Chiều ngang: Tỷ lệ của nhóm A (Ví dụ: Các phòng ban).
    - Chiều dọc: Tỷ lệ của nhóm B trong nhóm A đó (Ví dụ: Xếp loại nhân viên).
- **Ý nghĩa:** Biểu đồ Mosaic rất tốt để trả lời câu hỏi *"Tỷ lệ nhân viên Giỏi ở phòng Sales có nhiều hơn phòng IT không?"* mà không cần nhìn con số.

Ví dụ: Đánh giá xếp loại nhân sự (Low, Medium, High) của 3 phòng ban (HR, IT, Sales).

- **Phân tích hình:**
    - Nhìn cột Sale : cột màu đỏ  có diện tích của medium cao hơn so với IT và HR  -> Phòng Sale có năng lực trung bình.
    - Nhìn cột **IT**:  cột màu xanh lá  có diện tích của High chiếm diện tích rất lớn so với các màu khác. $\rightarrow$ Phòng IT có tỷ lệ nhân viên xuất sắc cao nhất.
    - Nhìn cột **HR**: cột màu xanh dương  có diện tích của Low chiếm diện tích lớn. $\rightarrow$ Phòng HR đang có vấn đề về hiệu suất.
    - Mosaic Plot giúp bạn nhìn thấy **tương quan tỷ lệ** ngay lập tức bằng mắt thường.

### (2) Chi-Square test ($x^2$)- kiểm định độc lập

Mosaic Plot cho ta thấy hình ảnh mối quan hệ. Chi-square Test cho ta con số để khẳng định mối quan hệ đó là thật hay ảo.

**Định nghĩa bài toán:**

- Câu hỏi: *"Việc khách hàng Nam mua hàng nhiều hơn Nữ là do ngẫu nhiên (tình cờ) hay thực sự Giới tính ảnh hưởng đến Mua hàng?"*
- **Giả thuyết $H_0$ (Null Hypothesis):** Hai biến độc lập .
- **Giả thuyết $H_1$:** Hai biến có quan hệ (Nam thích thể thao , Nữ thích mua sắm).

**Cơ chế hoạt động: (Kỳ vọng vs. Thực tế)**

- **Giả thuyết $H_0$ (Độc lập):** Giới tính và Mua hàng chả liên quan gì nhau. (Tỷ lệ mua của Nam và Nữ phải bằng nhau).
- **Thực tế (Observed):** Nam mua 60%, Nữ mua 40%.
- **Tính toán:** Chi-square đo khoảng cách giữa **Thực tế** và **Kỳ vọng**.
    - Khoảng cách càng lớn -> $\chi^2$ càng cao -> P-value càng nhỏ ($< 0.05$).

-> Bác bỏ $H_0$. Kết luận: **Giới tính CÓ ảnh hưởng đến Mua hàng.**

Quy tắc:

- **p-value < 0.05:** Bác bỏ $H_0$. $\rightarrow$ Có mối quan hệ. (Giới tính thực sự ảnh hưởng đến việc mua sắm).
- **p-value > 0.05:** Chấp nhận $H_0$. $\rightarrow$ Không liên quan. (Sự chênh lệch bạn thấy chỉ là ngẫu nhiên).

Ví dụ: Bạn tung đồng xu 100 lần. Kỳ vọng: 50 Ngửa - 50 Sấp. Thực tế: 99 Ngửa - 1 Sấp. Chi-square Test sẽ cho thấy: "P-value cực nhỏ! Đồng xu này chắc chắn bị gắn chì, không phải ngẫu nhiên!".

### (3) Pair plot - nhìn toàn cảnh dữ liệu

Khi có 4-5 biến số (Ví dụ: Doanh thu, Lợi nhuận, Tuổi, Điểm hài lòng), bạn không thể vẽ 10 cái scatterplot lẻ tẻ. Pair Plot vẽ tất cả trong một lần.

**Cấu trúc:** Là một ma trận các biểu đồ N x N.

- **Đường chéo chính:** Là Histogram/Density Plot của chính biến đó (xem phân phối).
- **Các ô còn lại:** Là Scatterplot giữa cặp biến giao nhau (xem tương quan).
- **Màu sắc (Hue):** Dùng biến phân loại (ví dụ: Loại khách hàng) để tô màu các

điểm, giúp phát hiện cụm (cluster) nhanh chóng.

**Ví dụ:** Dữ liệu Quảng cáo (TV, Radio, Báo chí) và Doanh số (Sales).

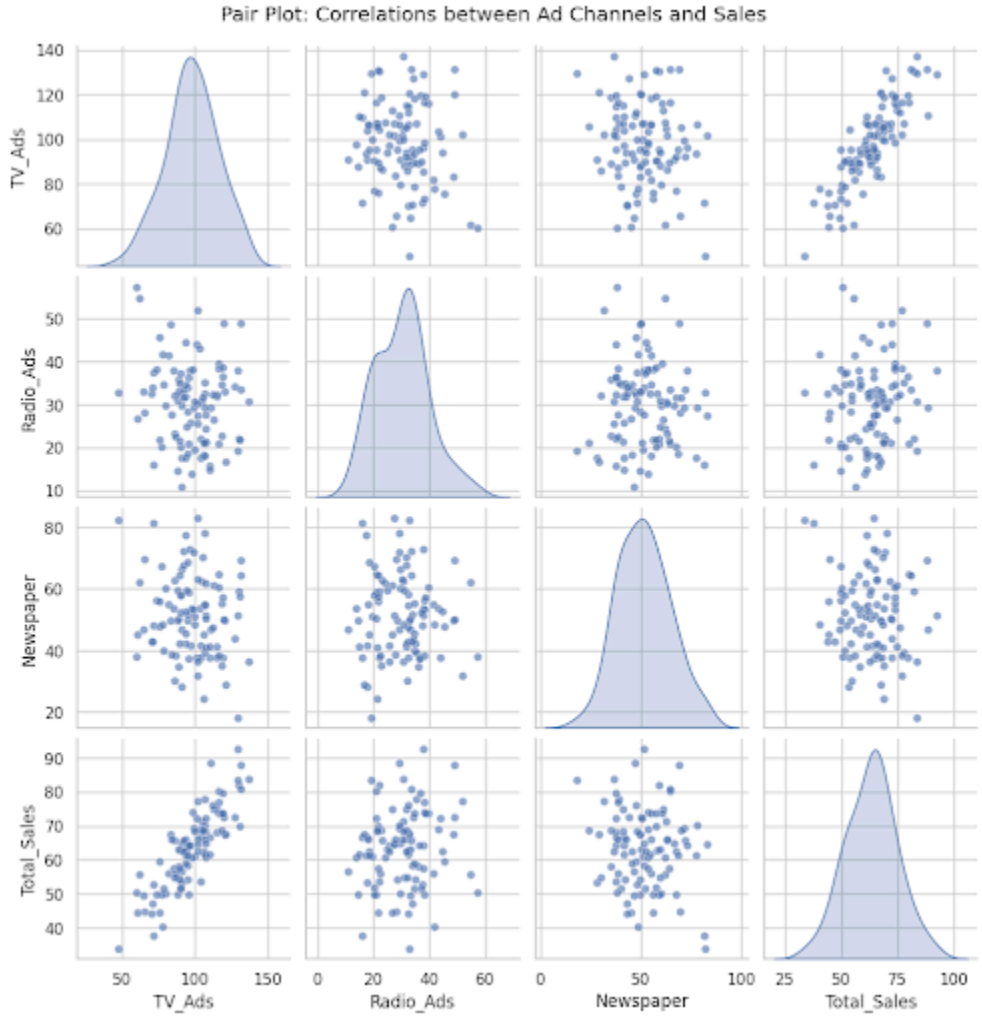


- **Phân tích hình:**
  - Nhìn dòng cuối cùng (Sales):
    - Ô TV vs Sales: Dữ liệu xếp thành đường chéo dốc lên rất đẹp. $\rightarrow$ Tương quan dương mạnh (TV càng nhiều, Sales càng tăng).
    - Ô Radio vs Sales: Cũng dốc lên nhưng phân tán hơn.
    - Ô Newspaper vs Sales: Dữ liệu như đám mây tròn vo, không có hình thù. $\rightarrow$ Tương quan yếu hoặc không có.
  - **Kết luận:** Nên dồn tiền vào TV và Radio, cắt giảm Báo chí.

(4) Dimensionality reduction (PCA) - Giảm chiều dữ liệu

Vấn đề “Quá tải thông tin ”:

Bạn có dữ liệu khách hàng với 50 cột: Tuổi, Thu nhập, Chi tiêu, Số lần web, Thời gian onl, Số con, Điểm tín dụng... Bạn không thể vẽ biểu đồ 50 chiều được. Mắt người chỉ nhìn được 2D hoặc 3D.. PCA giúp bạn "ép" 100 chiều đó xuống còn 2 chiều quan trọng nhất.

**Nguyên lí - phép chiếu bóng:** Hãy tưởng tượng một con Đại bàng đang bay (3D).

- Bạn không thể vẽ con đại bàng 3D lên tờ giấy.
- Nhưng bạn có thể vẽ **cái bóng** của nó xuống mặt đất (2D).
- Nếu mặt trời chiếu đúng góc, cái bóng 2D đó vẫn giữ được sải cánh và hình dáng đại bàng. **PCA (Principal Component Analysis) chính là cách tìm góc chiếu để cái bóng giữ lại nhiều thông tin nhất.**
- PCA tìm ra các "góc nhìn" (trục) mà tại đó dữ liệu biến thiên mạnh nhất. Nó xoay trục tọa độ để giữ lại lượng thông tin (variance) lớn nhất và loại bỏ các chiều thông tin nhiễu ít quan trọng.
- **Kết quả:** Từ 100 biến ($x_1, x_2... x_{100}$) $\rightarrow$ Tạo ra 2 biến mới ($PC1, PC2$).

**Các thành phần chính (Principal Components - PC)**

- **PC1 (Trục chính 1):** Là trục giữ lại nhiều thông tin nhất (Phương sai lớn nhất).
- **PC2 (Trục chính 2):** Vuông góc với PC1, giữ lại lượng thông tin lớn nhì

**Ứng dụng: Phát hiện Cụm & Outliers**

- Khi chiếu xuống 2D, các điểm dữ liệu có đặc tính giống nhau sẽ tự động tụ lại thành cụm.
- Những điểm nằm trơ trọi một mình rất xa đám đông chính là **Outliers đa chiều** (mà nếu nhìn từng biến đơn lẻ bạn sẽ không thấy).

Ví dụ: Phân khúc khách hàng dựa trên 5 hành vi: *Mua gần nhất (R), Tần suất (F), Giá trị (M), Tuổi, Thu nhập*. (Dữ liệu 5 chiều).

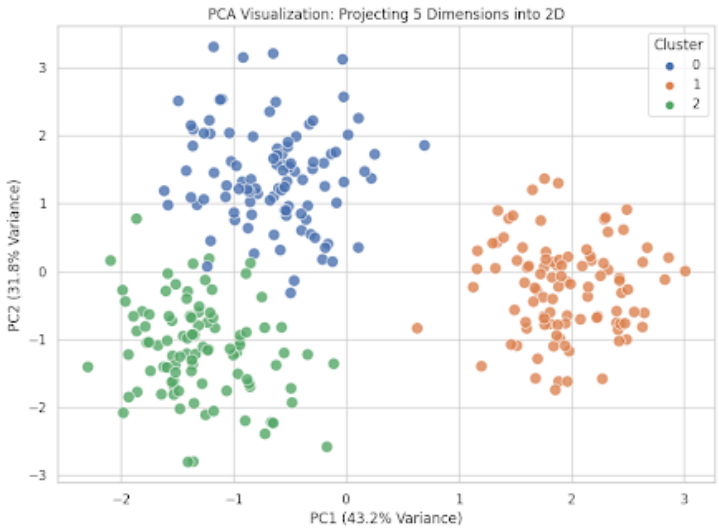


    - Chiếu 5 chiều xuống còn 2 chiều (PC1 và PC2).
    - Kết quả là biểu đồ Scatterplot 2D.
    - Bạn thấy 3 cụm điểm (Cluster) tách biệt rõ ràng.
        - Cụm 1: Khách VIP (Điểm cao trên cả 5 tiêu chí).
        - Cụm 2: Khách vãng lai.
        - Cụm 3: Khách sắp rời bỏ.
    - Bạn thấy các cụm này cách xa nhau, chứng tỏ 5 đặc tính ban đầu phân loại khách hàng rất tốt.
    - Nếu có một điểm chấm nằm tít ở góc xa, đó là khách hàng "dị biệt" cần chú ý.
- **Lợi ích:** Thay vì đau đầu với 5 biểu đồ, bạn chỉ cần nhìn 1 hình PCA để thấy cấu trúc phân nhóm tự nhiên của khách hàng.

### 4.4. Nghịch lý Simpson (Simpson's Paradox)

#### (1). Định nghĩa

Nghịch lý Simpson là hiện tượng "kỳ quái" khi một xu hướng rõ ràng xuất hiện trong từng nhóm con riêng lẻ, nhưng lại **biến mất** hoặc **đảo ngược hoàn toàn** khi gộp chung các nhóm đó lại với nhau.

- **Gọi là nghịch lý** vì logic thông thường bảo rằng: "Nếu A thắng B ở hiệp 1, và A thắng B ở hiệp 2, thì chung cuộc A phải thắng B". Nhưng trong thống kê, A vẫn có thể thua B chung cuộc.
- **Nguyên nhân:** Do sự **mất cân bằng mẫu** (sample imbalance) hoặc sự xuất hiện của một **Biến nhiễu (Confounding Variable)** ẩn đằng sau mà ta chưa xét đến.

### (2). Ví dụ: doanh thu và quảng cáo

**Bối cảnh:** Bạn so sánh hiệu quả của 2 kênh quảng cáo: **Facebook** và **Google**.

- **Dữ liệu tổng:** Giá trị đơn hàng trung bình (AOV) của Facebook là **500k**, của Google là **400k**.
- **Kết luận ban đầu:** "Facebook mang lại khách 'sộp' hơn".

**Khi EDA (Tách theo Thiết bị):**

- **Mobile:** Google AOV = 300k > Facebook AOV = 250k. (Google thắng).
- **Desktop:** Google AOV = 800k > Facebook AOV = 700k. (Google thắng).

**Giải thích**

- Người dùng Desktop thường mua đơn hàng to hơn Mobile.
- **Google** có lượng traffic từ Mobile chiếm 90% (kéo tụt trung bình xuống).
- **Facebook** có lượng traffic từ Desktop chiếm 60% (kéo trung bình lên).

$\rightarrow$ Thực tế Google hiệu quả hơn trên từng mặt trận, nhưng thua về mặt cơ cấu.

### (3). Nhận diện Simpson trên Biểu đồ Scatterplot (Số vs Số)

Không chỉ biến phân loại, nghịch lý này cũng xuất hiện khi phân tích tương quan tuyến tính (Regression).

- **Hiện tượng:**
  - Khi vẽ đường hồi quy cho toàn bộ dữ liệu (All data): Thấy xu hướng **Đi xuống** (Tương quan âm).
  - Khi tô màu (Color/Hue) và vẽ đường hồi quy cho từng nhóm con: Thấy xu hướng **Đi lên** (Tương quan dương).
  - Các đường xu hướng của nhóm con chạy song song ngược chiều với đường hồi quy tổng.
- **Ví dụ:** Mối quan hệ giữa **Số giờ tập thể dục** và **Nguy cơ bệnh tim**.
  - *Gộp chung:* Càng tập nhiều -> Nguy cơ bệnh càng cao (Vô lý?).
  - *Tách nhóm (Theo độ tuổi):*
    - Nhóm Trẻ: Tập nhiều -> Giảm bệnh.
    - Nhóm Già: Tập nhiều -> Giảm bệnh.
  - *Lý do:* Nhóm "Già" thường tập thể dục nhiều hơn (để giữ sức khỏe)

nhưng nguy cơ bệnh nền của họ vốn dĩ đã cao hơn nhóm "Trẻ". "Tuổi tác" chính là biến nhiễu làm đảo ngược xu hướng chung.

(4). Chiến lược xử lý trong EDA (Action Plan)

**01.** Luôn nghi ngờ số trung bình tổng hợp (Aggregated Mean): Đặc biệt khi các nhóm con có kích thước mẫu chênh lệch lớn.

**02.** Luôn Faceting/ Slicing :
Như đã đề cập ở phần 4.2, đừng bao giờ chỉ vẽ 1 biểu đồ tổng. Hãy dùng Facet Grid để chia nhỏ, cắt lát biểu đồ theo các biến phân loại quan trọng (Vùng miền, Giới tính, Nhóm tuổi).

- Đừng chỉ dừng lại ở groupby('Kênh_QC').mean().
- Hãy thử groupby(['Kênh_QC', 'Thiet_Bi']).mean().
- Hãy thử groupby(['Kênh_QC', 'Vung_Mien']).mean().

**03.** Kiểm tra sự phân bổ mẫu (Check Sample Distribution):
Dùng Frequency Table hoặc Heatmap để xem có sự mất cân bằng không.

- Tự hỏi: "Có yếu tố thứ 3 nào ảnh hưởng đến cả X và Y không?". Nếu có -> Cảnh báo Simpson
- Ví dụ: Khi so sánh Lương Nam vs Nữ, yếu tố thứ 3 là "Ngành nghề". (Nếu Nữ tập trung ở ngành lương thấp, trung bình sẽ thấp dù cùng vị trí lương họ cao hơn).

**04.** Tư duy "So sánh táo với táo" (Compare Apples to Apples):
Khi so sánh hiệu quả (như Thuốc A vs B), phải đảm bảo các điều kiện nền (như độ nặng bệnh) là tương đương nhau. Nếu không tương đương, phải chia nhỏ (segmentation) để so sánh.

**Phần 5: Xử lý ngoại lai và bất thường**

*Đừng vội xóa Outlier! Nó có thể là dữ liệu quan trọng nhất.*

Trước khi xóa bất cứ dữ liệu nào, hãy nhớ:

- **Rác :** Lỗi nhập liệu, máy hỏng. Ví dụ: Tuổi = 200. $\rightarrow$ **XÓA NGAY**.
- **Quan trọng :** Sự thật hiếm gặp. Ví dụ: Một giao dịch thẻ tín dụng lúc 3h sáng tại nước ngoài (có thể là gian lận hoặc khách đi du lịch). $\rightarrow$ **GIỮ LẠI** để phân tích.

### 5.1 Các phương pháp phát hiện giá trị ngoại lai :

Có 3 phương pháp phổ biến nhất để phát hiện các giá trị ngoại lai:

(1) Boxplot Rule: lưới lọc cơ bản

Đây là phương pháp phổ biến nhất trong EDA vì tính trực quan.

- **Nguyên lý:** Dựa trên **IQR (Khoảng tứ phân vị)**. Nó xác định một "hàng rào" (fences) an toàn. Bất kỳ điểm dữ liệu nào vượtb qua hàng rào này đều bị coi là kẻ ngoại lai.
- **Cách làm:**
    - Bước 1: Tìm Q1 (25%) và Q3 (75%).
    - Bước 2: Tính IQR (Khoảng cách giữa Q1 và Q3) : $IQR = Q3 - Q1$
    - Bước 3: Ngưỡng dưới (Lower Fence) = $Q1 - 1.5 \times IQR$
        - Ngưỡng trên (Upper Fence) = $Q3 + 1.5 \times IQR$
    - Bước 4: So sánh giá trị và kết luận giá trị outlier
- **Tại sao lại là 1.5?** John Tukey (cha đẻ EDA) chọn con số này vì trong phân phối chuẩn, nó bao phủ khoảng 99.3% dữ liệu. Phần còn lại (0.7%) được coi là ngoại lai.
- **Ví dụ tính toán:**
    - Dữ liệu lương: [10, 12, 11, 13, 100] (triệu đồng).
    - Sắp xếp: 10, 11, 12, 13, 100.
    - Bước 1: Tìm $Q1 (25%)= 11$, $Q3 (75%) = 13$.
    - Bước 2: $IQR = 2$.
    - Bước 3: Ngưỡng trên = $13 + 1.5 \times 2 = 16$.
    - Bước 4: So sánh và Kết luận**:** Số 100 > 16 $\rightarrow$ **Outlier**.

Biểu đồ dưới đây cho thấy "Hàng rào" (vạch đỏ). Các điểm nằm ngoài hàng rào (chấm đỏ) bị bắt lại.

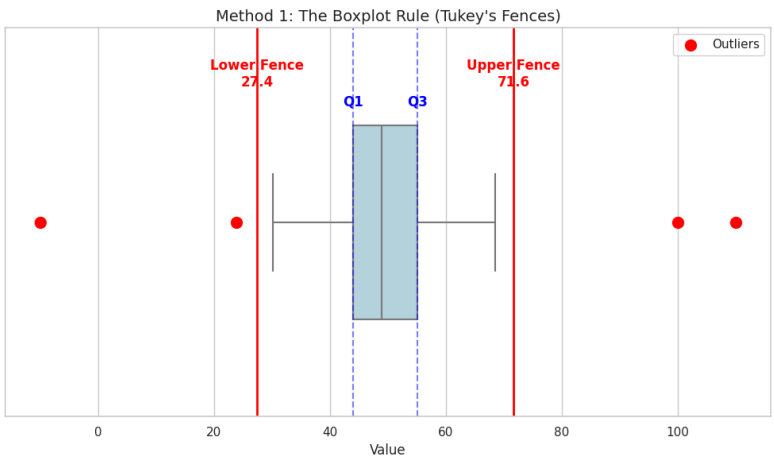


### (2). Phương pháp  Z-SCORE - "thước đo tiêu chuẩn"

Phương pháp này dựa trên Độ lệch chuẩn (SD). Cách này dùng toán học để đo xem một điểm dữ liệu "lệch lạc" bao nhiêu so với chuẩn mực chung.

**Công thức:**
$$Z = \frac{x - \text{Mean}}{\text{SD}}$$

**Quy tắc:** Nếu $|Z| > 3$, điểm đó là Outlier (Nằm ngoài 3-sigma).

**Nhược điểm :** Z-score rất yếu ớt trước các Outlier cực lớn.

- Khi có một Outlier quá lớn (ví dụ: 1 tỷ), nó sẽ kéo **Mean** tăng vọt , kéo lệch về phía đó  và làm **SD** phình to ra.
- Kết quả: Z-score của chính Outlier đó lại bị nhỏ đi (vì mẫu số SD quá lớn), khiến nó "ẩn mình" thành công.

**Ví dụ:** Nhóm lương: `[10tr, 10tr, 10tr, 1 tỷ]`.

- Trung bình sẽ bị kéo lên rất cao (khoảng 250tr).
- Khi đó, những người lương 10tr bỗng nhiên trở thành "xa trung bình" một cách vô lý, hoặc chính người lương 1 tỷ lại có Z-score không đủ lớn vì thước đo SD đã bị phình to.

**Tip:** Chỉ dùng Z-Score khi dữ liệu tuân theo **Phân phối Chuẩn (Normal Distribution)**.

### (3). Hampel identifier (Median & MAD)

Đây là phương pháp **Tốt nhất** để xử lý dữ liệu thực tế .

**Nguyên lý:** Thay thế Mean, SD ( dễ bị ảnh hưởng )  bằng Median, MAD (miễn nhiễm với outlier).

- **Median (Trung vị):** Dù có tỷ phú vào phòng, người đứng giữa (Median) vẫn không đổi.
- **MAD (Median Absolute Deviation):** Là khoảng cách trung bình từ mọi dữ liệu đến điểm  dữ liệu trung bình. Đây là thước đo độ rộng cực kỳ bền vững.

**Công thức:**
$$Z_{\text{robust}} = \frac{x - \text{Median}}{\text{MAD}}$$
(Thực tế thường nhân thêm hằng số 0.6745 để quy đổi về chuẩn Z-score).

**Quy tắc:** Nếu $|Z_{\text{robust}}| > 3.5$, điểm đó là Outlier.

**Sức mạnh:** Dù có một tỷ phú bước vào phòng, Median và MAD vẫn không thay đổi đáng kể. Tỷ phú đó sẽ bị phát hiện ngay lập tức vì khoảng cách từ ông ta đến Median là cực lớn, trong khi MAD (thước đo) vẫn nhỏ.

**Ví dụ :** Dữ liệu: [1, 2, 3, 4, 1000] (Số 1000 là lỗi).

- **Theo Z-score (Dựa vào Mean):**
  - Mean $\approx 200$. SD rất lớn.
  - Máy tính sẽ thấy số 1, 2, 3, 4 cách 200 không quá xa (so với SD). Nó có thể bỏ sót lỗi này hoặc đánh dấu sai.
- **Theo Hampel (Dựa vào Median):**
  - Median = 3.
  - Khoảng cách từ 1000 đến 3 là 997 (Rất lớn).
  - MAD (độ rộng bình thường của nhóm 1,2,3,4) rất nhỏ (khoảng 1).
  - Kết quả: $997 / 1 = 997$. Con số này lớn hơn ngưỡng 3.5 rất nhiều.
  - **Kết luận:** Máy tính khẳng định  "Số 1000 là Outlier chắc chắn!".

**5.2 Phân loại nguyên nhân:**

Sau khi đã "bắt" được các điểm ngoại lai (bằng Boxplot hoặc Hampel), cần phải đặt câu hỏi : **"Tại sao nó lại ở đây?"**.

Trường hợp 1: Dữ liệu lỗi

Đây là "Rác". Nó không phản ánh thực tế mà phản ánh sự sai sót của con người hoặc hệ thống.

- **Nhận diện:** Các giá trị vô lý về mặt vật lý hoặc logic.
- **Xử lí:**
    1. **Sửa (Correct):** Nếu biết nguyên nhân và logic sửa.
        - *Ví dụ:* Cột Chiều cao ghi là 1700. Đoán ngay là thiếu dấu chấm thập phân (cm vs m) $\rightarrow$ Sửa thành 170 hoặc 1.7.
    2. **Xóa (Remove/Drop):** Nếu không thể cứu vãn.
        - *Ví dụ:* Cột Tuổi = 200. Không biết là 20 hay lỗi máy tính $\rightarrow$ Xóa dòng đó.
    3. **Gán NA (Set to Null):** Nếu dòng dữ liệu đó chứa nhiều thông tin quý giá ở các cột khác, đừng xóa cả dòng. Hãy gán ô bị lỗi thành NA (Missing Value) rồi xử lý theo quy trình ở Phần 2.2.

### Trường hợp 2: Dữ liệu thật

Đây là "Sự thật". Dù nó lạ lùng nhưng nó đã xảy ra. Ví dụ: Một giao dịch trị giá 10 tỷ đồng (trong khi trung bình chỉ 500k). Nó làm xấu biểu đồ của bạn, nhưng nó là thực tế. **Tuyệt đối không được xóa tùy tiện**.

**Cách 1: Giữ nguyên giá trị :** Không làm gì cả. Để nguyên giá trị đó.

- **Cách này** dùng khi bạn dự định sử dụng các mô hình **Tree-based** (Cây quyết định) như: Random Forest, Gradient Boosting (XGBoost, LightGBM).
- **Tại sao?**
    - Các mô hình Tree hoạt động dựa trên quy tắc "Cắt" (Splitting). Ví dụ: Nếu Lương > 50 triệu thì....
    - Dù lương là 100 triệu hay 100 tỷ, nó đều rơi vào nhánh "Lớn hơn 50 triệu". Cây **không quan tâm khoảng cách** (Distance), **chỉ quan tâm thứ tự** (Rank). Do đó, Outlier không gây hại cho mô hình này.
- **Cảnh báo:** Nếu dùng Hồi quy tuyến tính (Linear Regression) hoặc KNN, cách này sẽ làm hỏng mô hình (vì các mô hình này dựa trên khoảng cách).
- **Ví dụ:** Trong bài toán phát hiện gian lận (Fraud Detection), các giao dịch Outlier chính là mục tiêu cần tìm. Xóa đi là xóa mất "kẻ gian".

**Cách 2: Biến đổi Log ( Log transformation)**

Dùng toán học để co ngắn khoảng cách giữa người giàu nhất và người nghèo nhất.

- **Sử dụng:** Khi dữ liệu bị lệch phải nặng (Right Skewed) và bạn muốn dùng các mô hình tuyến tính (Linear Regression, Logistic Regression, KNN)

- **Nguyên lý:** Hàm Logarit làm giảm tác động của các số cực lớn, nhưng vẫn giữ nguyên thứ tự của dữ liệu.
- **Công thức:** $x_{new} = \log(x)$ (hoặc $\log(x+1)$ nếu dữ liệu có số 0).
- **Ví dụ:**
    - Dữ liệu gốc (Lương): [10tr, 20tr, 1 tỷ]. (Khoảng cách: 990tr).
    - Biến đổi Log10:
        - $\log(10^7) = 7$
        - $\log(2 \times 10^7) \approx 7.3$
        - $\log(10^9) = 9$
    - Dữ liệu mới: [7, 7.3, 9].
    - **Kết quả:** Khoảng cách chỉ còn là 2 đơn vị. Outlier 1 tỷ đã bị "kéo" về gần với đám đông. Phân phối từ Lệch phải (Right Skewed) trở thành phân phối gần Chuẩn (Normal-like).

Cách 3: Winsorizing

Đây là một phương pháp trong thống kê dùng để điều chỉnh dữ liệu ngoại lai (outliers) bằng cách thay thế các giá trị cực trị xuống một mức độ nào đó.

- Sử dụng khi muốn giữ lại dòng dữ liệu đó (không muốn xóa) nhưng không muốn giá trị cực đoan phá hỏng tính toán thống kê
- **Nguyên lý:** Giới hạn dữ liệu trong khoảng từ $P1$ (Phân vị 1%) đến $P99$ (Phân vị 99%).
- **Cơ chế:** Thiết lập một mức trần (Ceiling) và mức sàn (Floor).
    - Thường dùng phân vị thứ 99 (P99) làm trần và phân vị thứ 1 (P1) làm sàn.
    - Mọi giá trị lớn hơn P99 sẽ bị gán bằng P99.
- **Cách làm:**
    - Bước 1: Tính giá trị tại $P99$ (Ví dụ: 500 triệu).
    - Bước 2: Tìm tất cả những ai có lương $> 500$ triệu (Ví dụ: 1 tỷ, 2 tỷ).
    - Bước 3: Gán lại lương của họ thành đúng $500$ triệu.

2. **Ví dụ :**
    - Dữ liệu: [10, 20, ..., 490, 500, 1000, 2000].
    - Ngưỡng P99 = 500.
    - Dữ liệu sau Winsorizing: [10, 20, ..., 490, 500, 500, 500].

    **Ý nghĩa:**

    - Bạn vẫn ghi nhận họ là "người lương cao nhất" (500tr).

- Nhưng bạn ngăn chặn việc con số 2 tỷ làm nổ tung phương sai của mô hình.
- Đây là cách cân bằng tuyệt vời giữa việc "giữ thông tin" và "giảm nhiễu".

**Phần 6: Kiểm định giả thuyết và tổng hợp**

**Mục tiêu:** Chuyển từ *"Cảm tính: nhóm A tốt hơn nhóm B"* (qua biểu đồ) sang *"khẳng định nhóm A tốt hơn nhóm B với độ tin cậy 95%"* ( bằng con số chính xác).

**6.1. Classical vs. Simulation**

Trong thống kê truyền thống (Classical), chúng ta thường ám ảnh với **T-test** hay **ANOVA** bằng các giả định: Dữ liệu phải phân phối chuẩn (hình chuông), phương sai phải đồng nhất, v.v. $\rightarrow$ **Thực tế:** Dữ liệu kinh doanh (doanh thu, lượt click, giá cổ phiếu) hiếm khi "chuẩn".

Giải pháp cho điều đó là phương pháp **Mô phỏng - Simulation**: Dùng sự linh hoạt và tính toán để "vẽ" ra phân phối thực tế.

(1). Kiểm định hoán vị - Permutation test

a. Định nghĩa:

Đây là cách kiểm tra sự khác biệt giữa 2 nhóm (A và B) bằng cách... giả vờ rằng chúng giống hệt nhau.

- Hãy tưởng tượng bạn trộn tất cả dữ liệu của A và B vào một cái hộp, xóc đều lên, rồi chia ngẫu nhiên lại thành 2 nhóm mới.
- Nếu sự khác biệt ban đầu của A và B lớn hơn hẳn so với sự khác biệt của các nhóm ngẫu nhiên này $\rightarrow$ A và B thực sự khác nhau.

**b. Quy trình thực hiện (Thuật toán):**

1. **Tính chênh lệch thực tế:** $\text{Diff}_{real} = \text{Mean}(A) - \text{Mean}(B)$.
2. **Trộn & Xào bài:** Gộp A và B lại, tráo đổi thứ tự ngẫu nhiên.
3. **Chia lại:** Rút ngẫu nhiên ra nhóm mới $A'$, còn lại là $B'$.
4. **Tính chênh lệch ảo:** $\text{Diff}_{random} = \text{Mean}(A') - \text{Mean}(B')$.
5. **Lặp lại:** Làm bước 2-4 khoảng 1,000 lần.

6. **Kết luận:** Nếu $\text{Diff}_{real}$ lớn hơn 95% các $\text{Diff}_{random}$ $\rightarrow$ Sự khác biệt là thật (có ý nghĩa thống kê).

**c. Ví dụ : A/B Testing giao diện Web.**

- **Tình huống:**
  - Nhóm A (Giao diện cũ): 100 khách, 10 người mua (10%).
  - Nhóm B (Giao diện mới): 100 khách, 15 người mua (15%).
  - *Câu hỏi:* Nhóm B tốt hơn thật hay do ăn may?
- **Dùng Permutation Test:**
  - Máy tính sẽ trộn 200 khách lại, bốc ngẫu nhiên 100 người vào nhóm ảo 1, 100 người vào nhóm ảo 2.
  - Sau 1000 lần bốc, máy tính bảo: *"Chỉ có 2% số lần bốc ngẫu nhiên tạo ra sự chênh lệch 5% như thế này"*.
  - **Kết luận:** Sự khác biệt là thật (P-value = 0.02). Giao diện mới thực sự hiệu quả.

**d. Ưu điểm:**

- Không quan tâm dữ liệu có Phân phối Chuẩn hay không.
- Dễ giải thích cho sếp (chỉ là bốc thăm ngẫu nhiên).

### (2). Lấy mẫu hoàn lại - Bootstrap

Người ta gọi phương pháp lấy mẫu hoàn lại - Bootstrap là *"The Swiss Army Knife"* (Dao đa năng) vì nó giải quyết được vấn đề đau đầu nhất: **Độ tin cậy của một con số**.

a. Định nghĩa:

Bạn chỉ có 1 tập dữ liệu duy nhất (Sample). Làm sao biết nó đại diện đúng cho cả thế giới (Population)?

$\rightarrow$ Bootstrap: Hãy coi tập dữ liệu đó là "thế giới thu nhỏ". Ta rút thăm từ nó, ghi lại, trả lại vào hộp, rồi rút tiếp (Sampling with Replacement). Làm 1000 lần để tạo ra 1000 "thế giới ảo".

**Định nghĩa:** Là kỹ thuật tạo ra hàng nghìn "tập dữ liệu ảo" từ tập dữ liệu gốc bằng cách lấy mẫu có hoàn lại (resampling with replacement).

**Mục tiêu:** Xây dựng **Khoảng tin cậy (Confidence Interval)** cho bất kỳ chỉ số nào (Mean, Median, Mode...) mà không cần nhớ công thức phức tạp.

**Tại sao nó là "Dao đa năng"?**

- Trong thống kê cổ điển, công thức tính Khoảng tin cậy cho *Trung bình (Mean)* thì dễ.
- Nhưng công thức tính Khoảng tin cậy cho *Trung vị (Median)* hay *IQR* thì cực kỳ phức tạp hoặc không tồn tại. Bootstrap xử lý được hết!

**b. Quy trình thực hiện:**

1. Lấy 1 mẫu (kích thước $n$) từ dữ liệu gốc, nhưng mỗi lần lấy xong thì **trả lại** (một điểm dữ liệu có thể được chọn nhiều lần).
2. Tính chỉ số quan tâm (Mean, Median, v.v.) của mẫu đó.
3. Lặp lại 1000 hoặc 10,000 lần.
4. Vẽ biểu đồ phân phối của 1000 chỉ số đó.
5. Xây dựng **Khoảng tin cậy (Confidence Interval)**: Cắt bỏ 2.5% đầu và 2.5% đuôi. Khoảng 95% ở giữa chính là vùng tin cậy.

**c. Ví dụ: Dự báo thu nhập trung bình.**

- **Dữ liệu:** Bạn khảo sát 50 người, thu nhập trung bình là 10 triệu/tháng. Nhưng có 1 ông lương 200 triệu (Outlier).
- **Vấn đề:** Con số 10 triệu này có tin được không? Hay do ông 200 triệu kéo lên? Sai số là bao nhiêu? $\pm 1$ triệu hay $\pm 5$ triệu?
- **Dùng Bootstrap:**
    - Máy tính tạo ra 10,000 mẫu ảo từ 50 người này. Có mẫu sẽ chứa ông 200 triệu 2 lần, có mẫu không chứa ông ấy lần nào.
    - Kết quả Bootstrap cho ra một khoảng: [8 triệu, 15 triệu].
    - **Kết luận:** *"Tôi tự tin 95% rằng thu nhập trung bình nằm trong khoảng 8-15 triệu"*. Đây là thông tin giá trị hơn nhiều so với con số trọc lốc "10 triệu".

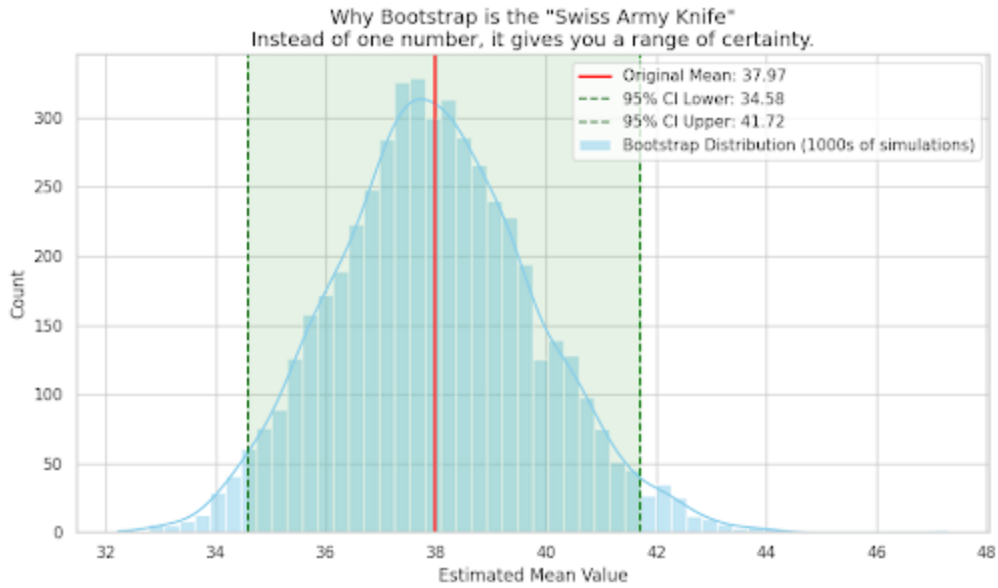


**Giải thích:**

- **Vạch đỏ (Original Mean):** Đây là con số duy nhất bạn có nếu dùng cách tính trung bình cổ điển (khoảng 38.0).
- **Vùng màu xanh (Bootstrap Distribution):** Nhờ Bootstrap, bạn thấy được hàng nghìn khả năng khác nhau của giá trị trung bình.
- **Vạch xanh lá (Confidence Interval):** Đây là "dao đa năng ". Nó khẳng định: "Dù mẫu gốc có nhiễu thế nào, trung bình thực tế chắc chắn 95% nằm trong khoảng này"

### 6.2. Feature Engineering (Kỹ thuật đặc trưng) từ EDA

Biến đổi dữ liệu thô thành dạng mà thuật toán "dễ học" nhất, giúp tăng độ chính xác của mô hình. Không phải cứ đưa dữ liệu thô vào là xong. Chúng ta cần biến đổi để khắc phục các điểm yếu của thuật toán. **Một mô hình tốt là việc kết hợp của Dữ liệu đẹp + thuật toán đơn giản > Dữ liệu xấu + Thuật toán cao siêu.**

#### (1) Transformation: Biến đổi dữ liệu

**Mục tiêu:** Xử lý độ lệch (Skewness). Hầu hết các thuật toán thống kê cổ điển (như Linear Regression) đều "thích" dữ liệu có hình cái chuông (Phân phối chuẩn). Tuy nhiên, dữ liệu thực tế (tiền bạc, dân số) thường bị méo.

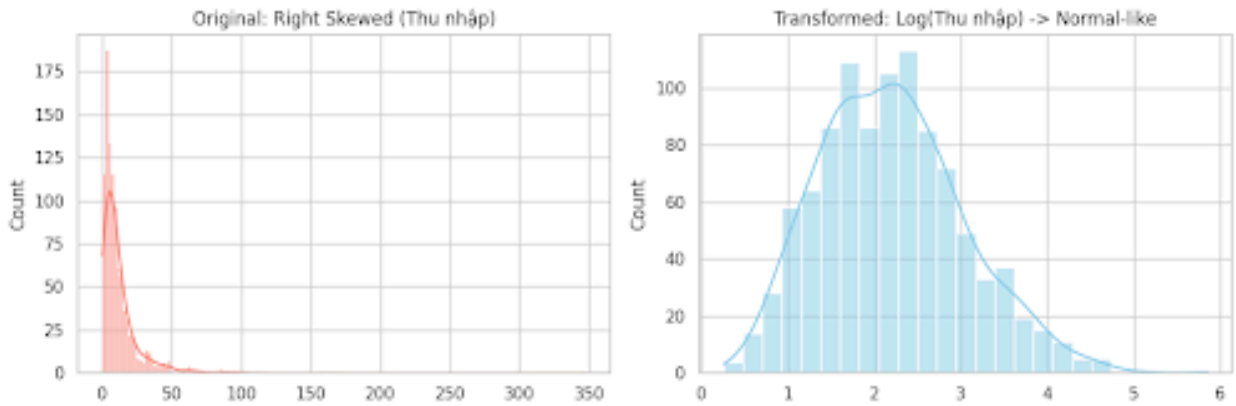


*Trái:* Dữ liệu gốc lệch phải (giống thu nhập), tập trung ở giá trị thấp nhưng đuôi kéo rất dài.

*Phải:* Sau khi dùng Log, dữ liệu trở thành hình chuông cân đối (Normal-like), giúp mô hình học dễ hơn.

**a) Skewness Handling:**

Dữ liệu thực tế thường bị méo (Skewed). Ví dụ: Thu nhập, Giá nhà thường bị lệch phải (Right Skewed).

- **Vấn đề:** Các thuật toán tuyến tính giả định dữ liệu phân phối chuẩn (hình chuông cân đối). Nếu dữ liệu bị lệch, mô hình sẽ dự báo sai ở phần đuôi.

Dấu hiệu nhận biết độ lệch:

**Lệch phải (Right Skewed):** Đuôi dài về phía giá trị lớn (Ví dụ: Thu nhập, Giá nhà, Số lượt like).

- *Đặc điểm:* Mean > Median. Các giá trị khổng lồ (Outlier) kéo Mean đi xa.
- *Giải pháp:* "Co" cái đuôi dài lại.
  - **Log Transform:** $\log(x+1)$. Mạnh nhất, dành cho dữ liệu biến động cực lớn (như lương tỷ phú).
  - **Square Root (Sqrt):** $\sqrt{x}$. Nhẹ hơn Log, dùng cho dữ liệu đếm (Count data) như số lượt khách vào cửa.
  - **Box-Cox:** Phương pháp tự động tìm ra phép biến đổi tối ưu nhất (cần dữ liệu dương).
- *Mục tiêu:* Đưa phân phối về dạng "Normal-like" để mô hình không bị các giá trị cực lớn làm nhiễu.

**Lệch trái (Left Skewed):** Đuôi dài về phía giá trị nhỏ (Ví dụ: Tuổi thọ, Điểm thi tốt nghiệp).

- *Giải pháp:* Dùng hàm mũ ($x^2, x^3$) hoặc hàm mũ cơ số $e$ ($e^x$).

- **Giải pháp:**
  - **Log Transformation ($\log(x)$):** Dùng cho độ lệch phải **rất lớn** (Ví dụ: Thu nhập chênh nhau hàng tỷ đồng). Nó co ngắn khoảng cách giữa người giàu và nghèo.
  - **Square Root ($\sqrt{x}$):** Dùng cho độ lệch **nhẹ hơn** (Ví dụ: Số lượng khách vào cửa hàng).
  - **Box-Cox Transformation:** Là vũ khí tối thượng, tự động tìm ra hàm biến đổi tốt nhất (mũ bao nhiêu) để đưa dữ liệu về chuẩn nhất có thể.
- **Ví dụ:** Dự báo giá nhà.
  - Giá nhà: [1 tỷ, 2 tỷ, ..., 100 tỷ]. (Lệch phải nặng).
  - Nếu giữ nguyên: Mô hình sẽ bị số 100 tỷ làm nhiễu.
  - Sau khi Log: Giá trị trở thành [9.0, 9.3, ..., 11.5]. Phân phối trở nên đẹp đẽ, mô hình dễ học hơn hẳn.

**b) Scaling (Chuẩn hóa): Đưa về cùng hệ quy chiếu**

Máy tính không hiểu đơn vị (Tuổi vs Tiền). Nó chỉ hiểu con số.

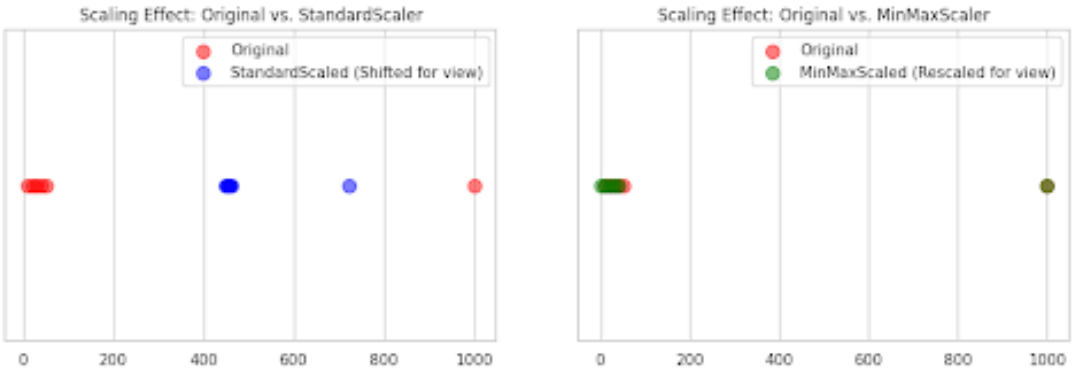


Minh họa sự khác biệt khi co giãn dữ liệu. Lưu ý rằng MinMaxScaler (bên phải) bị ảnh hưởng bởi điểm Outlier (điểm ngoài cùng bên phải) khiến các điểm còn lại bị ép chặt vào nhau.

**Ví dụ:** Bạn có 2 cột:

  - Tuổi: 20 đến 60 (Khoảng biến thiên = 40).
  - Lương: 10 triệu đến 100 triệu (Khoảng biến thiên = 90 triệu).
- **Hậu quả:** Máy tính sẽ nghĩ: *"Lương thay đổi 1 đơn vị (1 đồng) quan trọng ngang với Tuổi thay đổi 1 đơn vị (1 tuổi)"*.

$\rightarrow$ Thực tế: Lệch 1 tuổi quan trọng hơn lệch 1 đồng rất nhiều! Mô hình sẽ bị thiên vị hoàn toàn theo cột Lương và lờ đi cột Tuổi.

**Các kỹ thuật Scaling**

- **StandardScaler (Z-score Normalization):- "Phổ biến nhất**
    - *Công thức:* $z = \frac{x - \text{Mean}}{\text{SD}}$
    - *Tác dụng:* Đưa dữ liệu về dạng có **Trung bình = 0** và **Độ lệch chuẩn = 1**.
    - *Kĩ thuật này được dùng khi* hầu hết các thuật toán (Linear Regression, Logistic Regression, SVM). Nó giữ lại thông tin về Outlier (vì không ép vào khung cố định).
    - Ví dụ:
        - **Cách làm:** Kéo tất cả các cột về cùng một chuẩn: **Trung bình = 0** và **Độ lệch chuẩn = 1**.
        - **Ý nghĩa:** Nó biến đổi giá trị thành *"Bạn cách trung bình bao nhiêu độ lệch chuẩn?"*.
            - Người 30 tuổi (Trung bình) $\rightarrow$ 0.
            - Người 60 tuổi (Rất già) $\rightarrow$ +2.
            - Lương 50 triệu (Trung bình) $\rightarrow$ 0.
            - Lương 100 triệu (Rất cao) $\rightarrow$ +2.
        - **Kết quả:** Cả Tuổi và Lương đều nằm trong khoảng từ -3 đến +3. Máy tính giờ đây coi trọng 2 biến này như nhau.
        - **Dùng cho:** Hầu hết các thuật toán (Linear Regression, Logistic Regression, SVM).

- **MinMaxScaler (Normalization: 0-1)- "Ép vào khuôn khổ":**
    - *Công thức:* $x_{new} = \frac{x - \text{Min}}{\text{Max} - \text{Min}}$
    - *Tác dụng:* Ép tất cả dữ liệu vào khoảng **[0, 1]**.
    - *Kĩ thuật này được dùng khi :*
        - **Neural Networks (Deep Learning):** Vì hàm kích hoạt (Activation function) thường hoạt động tốt trong khoảng 0-1.
        - **Thuật toán khoảng cách (KNN, K-Means):** Cần độ nhạy cao.
        - *Lưu ý:* Rất nhạy cảm với Outlier (nếu có 1 Outlier cực lớn, toàn bộ dữ liệu còn lại sẽ bị ép dẹp lép về số 0).

Ví dụ:

- **Cách làm:** Ép giá trị nhỏ nhất thành 0, lớn nhất thành 1. Mọi giá trị khác nằm ở giữa.

- **Kết quả:** Tuổi 20 $\rightarrow$ 0; Tuổi 60 $\rightarrow$ 1. Lương 10tr $\rightarrow$ 0; Lương 100tr $\rightarrow$ 1.
- **Dùng cho:**
    - **Neural Networks (Deep Learning):** Vì các hàm kích hoạt (như Sigmoid) thích làm việc trong khoảng 0-1.
    - **Xử lý ảnh:** Giá trị pixel từ 0-255 được ép về 0-1.
- **Điểm yếu:** Rất sợ Outlier. Nếu có 1 ông lương 100 tỷ, thì ông ấy là 1, còn tất cả người lương 100 triệu sẽ bị ép dẹp lép xuống thành 0.001 (gần như bằng 0).

(2). Discretization ( Rời rạc hóa / Binning) - "Kĩ Thuật chia để trị"

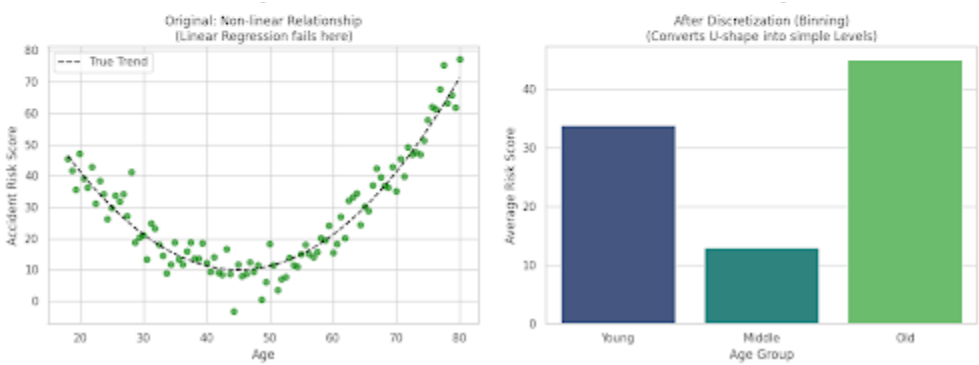


*Trái:* Mối quan hệ hình chữ U (Phi tuyến) giữa Tuổi và Rủi ro. Đường thẳng không thể vẽ xuyên qua đây được.

*Phải:* Sau khi chia nhóm (Young, Middle, Old), ta thấy rõ mô hình bậc thang: Cao - Thấp - Cao. Mối quan hệ trở nên đơn giản hơn để xử lý.

**Mục tiêu:** Biến đổi biến số liên tục (Continuous) thành biến phân loại (Categorical) để xử lý các mối quan hệ phi tuyến (Non-linear).

**Vấn đề (Phi tuyến tính)**

- **Tình huống:** Mối quan hệ giữa **Tuổi** và **Chi phí y tế**.
    - Trẻ em (0-5 tuổi): Ốm nhiều $\to$ Chi phí cao.

    - Thanh niên (18-30): Khỏe mạnh $\to$ Chi phí thấp.
    - Người già (>60): Yếu $\to$ Chi phí rất cao.
- **Hậu quả:** Mối quan hệ là hình chữ **U**. Nếu bạn dùng Linear Regression (đường thẳng), mô hình sẽ thất bại thảm hại (đường thẳng không thể uốn cong hình chữ U).

**Giải pháp:** Chia Tuổi thành 3 nhóm: Thiếu niên, Trung niên, Lão niên. Khi đó, mô hình sẽ học được hệ số rủi ro riêng cho từng nhóm.

**Các kỹ thuật Binning:**

1. **Equal Width:** Chia đều khoảng giá trị (0-10, 10-20...). Dễ bị ảnh hưởng bởi Outlier.
2. **Equal Frequency (Quantile Binning):** Chia sao cho mỗi nhóm có số lượng người bằng nhau (Ví dụ: 4 nhóm, mỗi nhóm 25% dân số). Đây là cách tốt nhất để xử lý Outlier và Skewness.

Ví dụ : Thay vì để tuổi liên tục, ta chia thành 3 cái giỏ (Bins):

1. **Nhóm Young (< 30):** Gán mã `High_Risk`.
2. **Nhóm Middle (30-60):** Gán mã `Low_Risk`.
3. **Nhóm Old (> 60):** Gán mã `High_Risk`.
- **Kết quả:**
    - Mối quan hệ phức tạp (Cong) đã biến thành mối quan hệ bậc thang đơn giản (Cao - Thấp - Cao).
    - Các mô hình tuyến tính giờ đây có thể học dễ dàng: *"Nếu là Middle thì rủi ro thấp, còn lại thì cao"*.
- **Lợi ích phụ:** Xử lý tốt Outlier (Ông 100 tuổi cũng chỉ nằm chung nhóm Old với ông 70 tuổi, không làm lệch mô hình).

.

### 6.3. Kiểm định giả thuyết (Hypothesis Testing - Modern Approach)

Thay vì ám ảnh với p-value theo cách truyền thống:

- P-value < 0.05 chỉ nói rằng sự khác biệt là "có thật" (thống kê), nhưng không nói nó có "quan trọng" (thực tế) hay không.
- Còn với dữ liệu lớn (Big Data), ngay cả một sự khác biệt bé tí (ví dụ: chênh lệch 1 đồng) cũng có thể cho ra P-value siêu nhỏ. Điều này dẫn đến kết luận sai lầm về mặt kinh doanh.

Có 2 phương pháp để kiểm định giả thuyết:

    - **Permutation Test (Kiểm định hoán vị):** Trộn lẫn dữ liệu các nhóm và xem sự khác biệt có xảy ra ngẫu nhiên không.
    - **Effect Size (Kích thước hiệu ứng):** Đo độ lớn của sự khác biệt (ví dụ: Cohen's d) thay vì chỉ nói "có khác biệt".

**(1) Kiểm định giả thuyết**

*(Lưu ý: Cơ chế thuật toán đã trình bày ở 6.1. Tại đâtáex tập trung vào cách đọc biểu đồ kết quả).*

a. Tư duy "Thế giới giả lập" (Null Hypothesis World):

Khi chạy Permutation Test, bạn tạo ra hàng nghìn kết quả "ảo". Biểu đồ Histogram của các kết quả này đại diện cho "Sự ngẫu nhiên".

- Nếu sự khác biệt thực tế của nằm **chìm nghỉm** trong đám mây ngẫu nhiên này $\rightarrow$ Không có gì đặc biệt.
- Nếu sự khác biệt thực tế nằm **tách biệt hẳn** ra ngoài rìa $\rightarrow$ Đó là sự khác biệt thật (Có ý nghĩa thống kê).

b. Cách đọc biểu đồ (Visual Inference):

Thay vì nhìn con số P-value (ví dụ 0.03), hãy nhìn hình ảnh:

- **Vùng màu xám (Histogram):** Là tiếng ồn (Noise/Random Chance).
- **Vạch đỏ (Observed Difference):** Là tín hiệu (Signal) bạn thu được.
- **Quy tắc:** Vạch đỏ càng đứng xa vùng màu xám, bạn càng tự tin.

**Ví dụ: Chiến dịch Marketing**

- **Tình huống:**
    - Nhóm Khách hàng nhận Email A: Chi tiêu trung bình **500k**.
    - Nhóm Khách hàng nhận Email B: Chi tiêu trung bình **550k**.
    - Chênh lệch thực tế: **50k**.
- **Câu hỏi:** 50k này là do Email B tốt thật, hay do may mắn vớ được khách sộp?

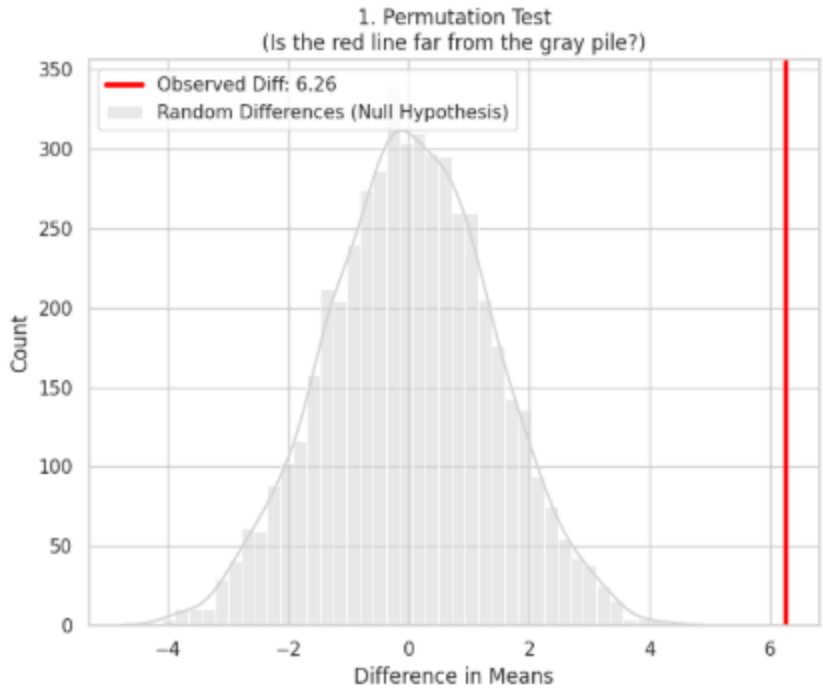


- **Chạy Permutation Test:**
  - Máy tính trộn hết khách lại, chia ngẫu nhiên 1000 lần.
  - Kết quả: Chỉ có 5 lần (trong 1000 lần) việc chia ngẫu nhiên tạo ra chênh lệch > 50k.
  - **Kết luận:** Xác suất ngẫu nhiên là 0.5% (rất thấp). Vậy sự khác biệt 50k là **DO EMAIL B HIỆU QUẢ THẬT**.

**(2) Kích thước hiệu ứng - Effect size: đo độ lớn của sự khác biệt**

Bởi vì P-value chỉ trả lời câu hỏi Yes/No (Có khác biệt hay không). Còn Effect Size trả lời câu hỏi How much? (Khác biệt lớn đến mức nào?).

- *Ví dụ:* Thuốc giảm cân mới giúp giảm 100 gram sau 1 năm.
  - P-value < 0.05 (Khẳng định có giảm thật).
  - Nhưng Effect Size cực nhỏ (Giảm 1 lạng chả bõ bèn gì). $\rightarrow$ Không đáng để kinh doanh.

b. Chỉ số phổ biến: Cohen's d

Công thức đơn giản hóa:

$$d = \frac{\text{Mean}_1 - \text{Mean}_2}{\text{Độ lệch chuẩn chung (Pooled SD)}}$$

**c. Cách đọc chỉ số Cohen's d:**

- **$d \approx 0.2$ (Nhỏ):** Sự khác biệt có thật nhưng mắt thường khó thấy. (Ví dụ: Chiều cao trung bình người miền Bắc vs miền Nam).
- **$d \approx 0.5$ (Trung bình):** Sự khác biệt đủ để nhận ra.
- **$d \approx 0.8$ (Lớn):** Sự khác biệt rõ rệt "như ban ngày". (Ví dụ: Chiều cao người lớn vs Trẻ em).

**d. Ví dụ: Tối ưu website (Web Optimization)**

- **Tình huống:** Thay đổi màu nút "Mua hàng" từ Xanh sang Đỏ.
  - Nút Xanh: Tỷ lệ click 5.0%.
  - Nút Đỏ: Tỷ lệ click 5.1%.
  - Số lượng mẫu: 1 triệu lượt truy cập.
- **Phân tích:**
  - **P-value:** < 0.001 (Siêu nhỏ, vì mẫu quá lớn). Khẳng định nút Đỏ tốt hơn nút Xanh.
  - **Effect Size (Cohen's d):** 0.01 (Siêu nhỏ).
- **Quyết định kinh doanh:** Dù nút Đỏ tốt hơn thật (về mặt thống kê), nhưng mức tăng 0.1% quá nhỏ, không bõ công thay đổi thiết kế toàn bộ web. Giữ nguyên nút Xanh.

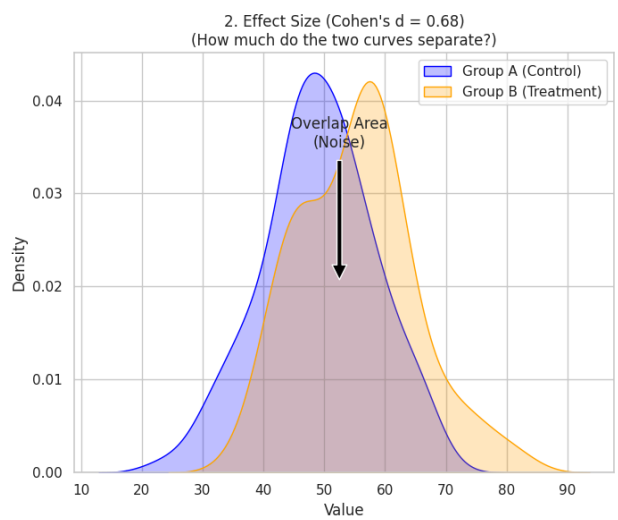


Insight: Hai quả núi (Xanh và Cam) đại diện cho 2 nhóm.

**Cách đọc:** Hai quả núi càng tách xa nhau thì **Cohen's d** càng lớn (Effect Size càng mạnh). Ở đây $d \approx 0.5$, nghĩa là có sự khác biệt trung bình – hai nhóm có chồng lấn (overlap) nhưng vẫn phân biệt được.

**Phần 7: Data Storytelling**

- Tóm tắt các phát hiện chính (Key Findings).
- **Validity Check:** Dữ liệu này có đủ trả lời câu hỏi kinh doanh ban đầu không? (Nếu thiếu biến quan trọng -> Yêu cầu thu thập thêm).
- **Baseline:** Đưa ra một con số cơ sở (Ví dụ: Nếu đoán mò theo giá trị trung bình thì sai số là bao nhiêu? Mô hình phức tạp cần đánh bại con số này).
- Cảnh báo về chất lượng dữ liệu.
- Đề xuất mô hình phù hợp (ví dụ: Nếu dữ liệu quan hệ phi tuyến, đừng dùng Linear Regression).