Phân nhóm và phân đoạn trong khai phá dữ liệu

1. Khái niệm về phân tích phân cụm (Clustering)

Phân cụm là một phương pháp khai phá dữ liệu không giám sát, nhằm nhóm các đối tượng dữ liệu giống nhau vào cùng một nhóm (cụm) dựa trên các tiêu chí nhất định. Hai đối tượng giống nhau sẽ nằm trong cùng cụm, trong khi hai đối tượng khác nhau sẽ thuộc các cụm riêng biệt. Mục tiêu chính là tối thiểu hóa khoảng cách giữa các phần tử trong cùng cụm và tối đa hóa khoảng cách giữa các phần tử thuộc các cụm khác nhau.

- **Định nghĩa cơ bản**: Cụm là tập hợp các đối tượng dữ liệu có đặc tính tương đồng. Phân tích phân cụm không yêu cầu nhãn lớp trước (không giám sát), khác với phân loại (có giám sát). Số lượng cụm không được xác định trước, và kết quả phụ thuộc vào độ đo tương đồng.

Ví dụ minh họa thực tế: Trong tiếp thị, phân cụm khách hàng dựa trên dữ liệu mua sắm để xác định nhóm khách hàng tiềm năng. Chẳng hạn, một công ty bán lẻ có thể phân cụm khách hàng thành các nhóm như "sinh viên trẻ tuổi mua hàng giá rẻ", "người làm văn phòng mua sản phẩm cao cấp", hoặc "người về hưu mua hàng thiết yếu". Điều này giúp tối ưu hóa chiến dịch quảng cáo.

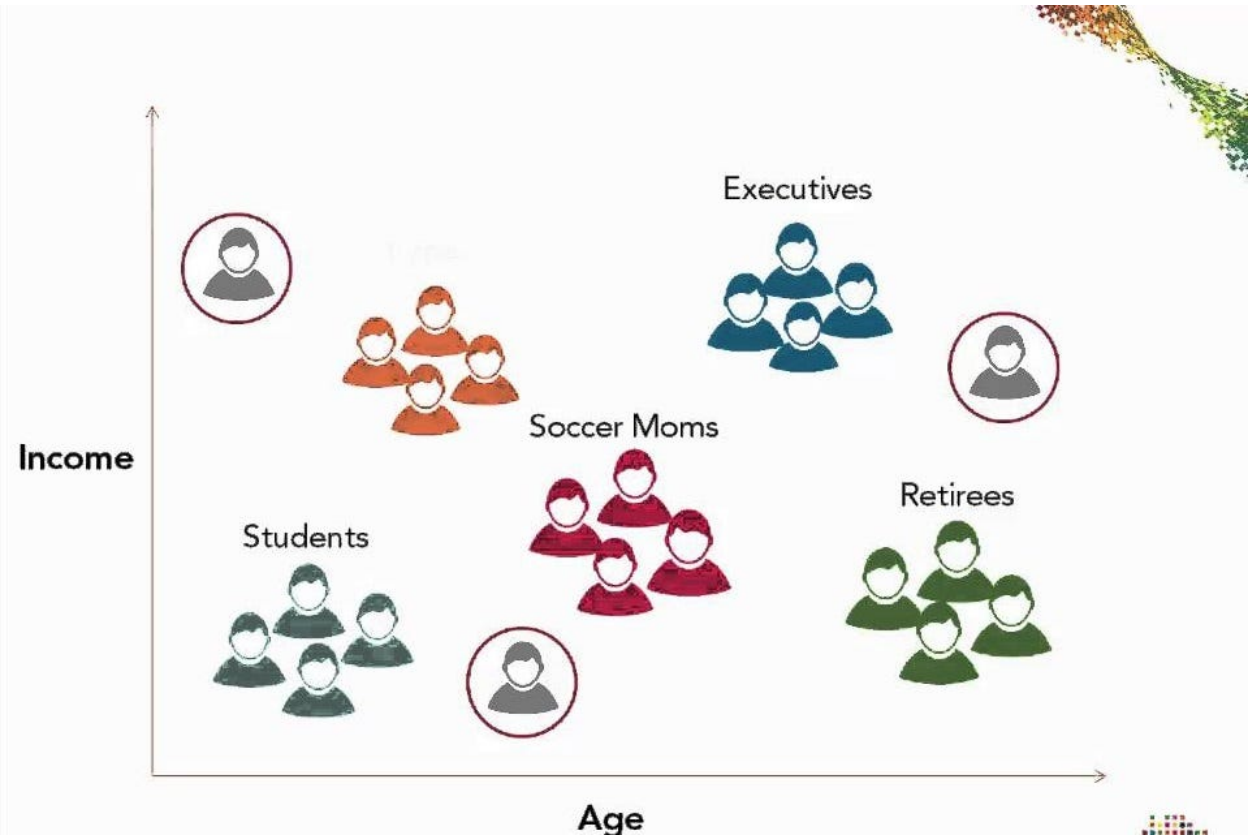

devpost.com

Hình ảnh minh họa phân đoạn khách hàng sử dụng K-means clustering trong tiếp thị.

2. Ứng dụng của phân cụm trong khai phá dữ liệu

Phân cụm được áp dụng rộng rãi trong nhiều lĩnh vực để khám phá mẫu ẩn trong dữ liệu:

- **Tiếp thị và kinh doanh**: Phát hiện nhóm khách hàng đặc biệt để phát triển chương trình tiếp thị mục tiêu. Ví dụ: Netflix sử dụng phân cụm để nhóm người dùng dựa trên lịch sử xem phim, từ đó gợi ý nội dung cá nhân hóa, tăng tỷ lệ giữ chân khách hàng lên đến 75%.
- **Sử dụng đất và môi trường**: Xác định các vùng sử dụng đất tương đồng từ dữ liệu quan sát Trái Đất. Ví dụ: NASA phân cụm dữ liệu vệ tinh để xác định khu vực ô nhiễm hoặc thay đổi khí hậu, hỗ trợ lập kế hoạch bảo vệ môi trường.
- **Bảo hiểm**: Nhóm khách hàng có rủi ro cao, như phân cụm người mua bảo hiểm ô tô dựa trên lịch sử tai nạn để điều chỉnh phí bảo hiểm. Ví dụ: Công ty bảo hiểm Geico sử dụng phân cụm để dự đoán nhóm khách hàng có tỷ lệ bồi thường cao, giảm thiểu rủi ro tài chính.
- **Lập kế hoạch đô thị**: Nhóm nhà ở dựa trên kiểu nhà, giá trị và vị trí địa lý. Ví dụ: Tại Việt Nam, phân cụm dữ liệu bất động sản ở TP.HCM để xác định khu vực "nhà cao cấp quận 1" hoặc "nhà giá rẻ ngoại ô", hỗ trợ quy hoạch đô thị.
- **Nghiên cứu động đất**: Phân cụm địa chấn dựa trên lỗi lục địa để dự đoán rủi ro. Ví dụ: Ở Nhật Bản, phân cụm dữ liệu địa chấn giúp xác định vùng dễ xảy ra động đất mạnh, hỗ trợ cảnh báo sớm.
- **Xử lý ảnh và không gian**: Phân đoạn hình ảnh để nhận dạng vật thể, hoặc phân tích dữ liệu GIS. Ví dụ: Google Maps sử dụng phân cụm để nhóm các điểm dữ liệu giao thông, dự đoán tắc nghẽn.

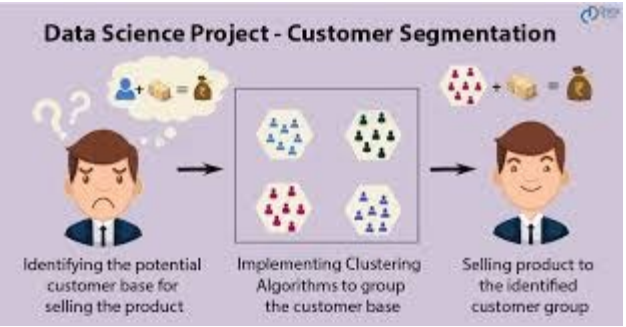

[data-flair.training]

Quy trình phân đoạn khách hàng trong dự án khoa học dữ liệu, từ xác định cơ sở đến bán hàng.

3. Yêu cầu của phân cụm trong khai phá dữ liệu

Một phương pháp phân cụm tốt cần đáp ứng các tiêu chí sau để phù hợp với dữ liệu lớn và đa dạng:

- Tính mở rộng về kích cỡ dữ liệu.
- Xử lý các kiểu thuộc tính khác nhau (số, phân loại, văn bản).
- Phát hiện cụm có hình thù bất kỳ (không chỉ hình cầu).
- Yêu cầu ít tri thức miền để xác định tham số.
- Không bị ảnh hưởng bởi trật tự dữ liệu đầu vào.
- Xử lý dữ liệu nhiều chiều và có nhiễu/ngoại lai.
- Cho phép thêm ràng buộc từ người dùng.
- Kết quả dễ diễn giải và sử dụng.

4. Độ đo trong phân cụm

Độ đo tương đồng (similarity) hoặc khoảng cách (distance) là yếu tố quan trọng để phân cụm. Dữ liệu thường được biểu diễn dưới dạng ma trận dữ liệu (n phần tử x p đặc tính) hoặc ma trận khoảng cách.

Ví dụ: Trong phân đoạn khách hàng, khoảng cách Euclidean được dùng để đo sự khác biệt giữa thu nhập và tuổi tác của khách hàng.

- **Khoảng cách phổ biến**:
  - Minkowski: $d(i,j) = \sqrt[q]{|x_{i1} - x_{j1}|^q + \cdots + |x_{ip} - x_{jp}|^q}$
    - q=1: Manhattan (khoảng cách thành phố).
    - q=2: Euclidean (khoảng cách thẳng).
  - Cosine similarity: Dùng cho dữ liệu văn bản, $\cos(d1, d2) = \frac{d1 \cdot d2}{\|d1\| \|d2\|}$.
- **Đối với biến nhị phân**: Sử dụng ma trận contingency để tính Jaccard coefficient cho biến không đối xứng.
- **Chuẩn hóa dữ liệu**: Sử dụng z-score để tránh thiên kiến: $z_{if} = \frac{x_{if} - m_f}{s_f}$.

5. Phân loại phân cụm

Phân cụm có thể được phân loại theo các đặc tính:

- **Loại trừ/Không loại trừ**: Các điểm có thể thuộc nhiều cụm (không loại trừ) hoặc chỉ một (loại trừ).
- **Mờ/Không mờ**: Trong phân cụm mờ, điểm thuộc cụm với xác suất (tổng xác suất =1).
- **Một phần/Toàn bộ**: Phân cụm chỉ một phần dữ liệu hoặc toàn bộ.
- **Hỗn tạp/Đồng điệu**: Cụm có kích cỡ, hình dạng khác nhau (hỗn tạp) hoặc tương đồng.

Các loại cụm chính:

- **Phân chia rõ ràng**: Mỗi điểm gần nhất với cụm của nó hơn các cụm khác (ví dụ: K-means).
- **Dựa trên trung tâm**: Cụm được đại diện bởi một điểm trung tâm (centroid).
- **Dựa trên mật độ**: Cụm là vùng có mật độ điểm cao (ví dụ: DBSCAN cho dữ liệu nhiễu).
- **Dựa trên khái niệm**: Cụm dựa trên mô tả khái niệm (conceptual clustering).

6. Phương pháp phân cụm

Các phương pháp phổ biến bao gồm:

- **K-means**: Chọn k trung tâm ban đầu, gán điểm vào trung tâm gần nhất, cập nhật trung tâm đến khi hội tụ. Ưu điểm: Đơn giản, nhanh; Nhược điểm: Phụ thuộc k ban đầu, chỉ phù hợp cụm hình cầu.

Ví dụ thực tế: Amazon sử dụng K-means để phân cụm khách hàng dựa trên lịch sử mua hàng, giúp gợi ý sản phẩm chính xác hơn, tăng doanh số 35%.

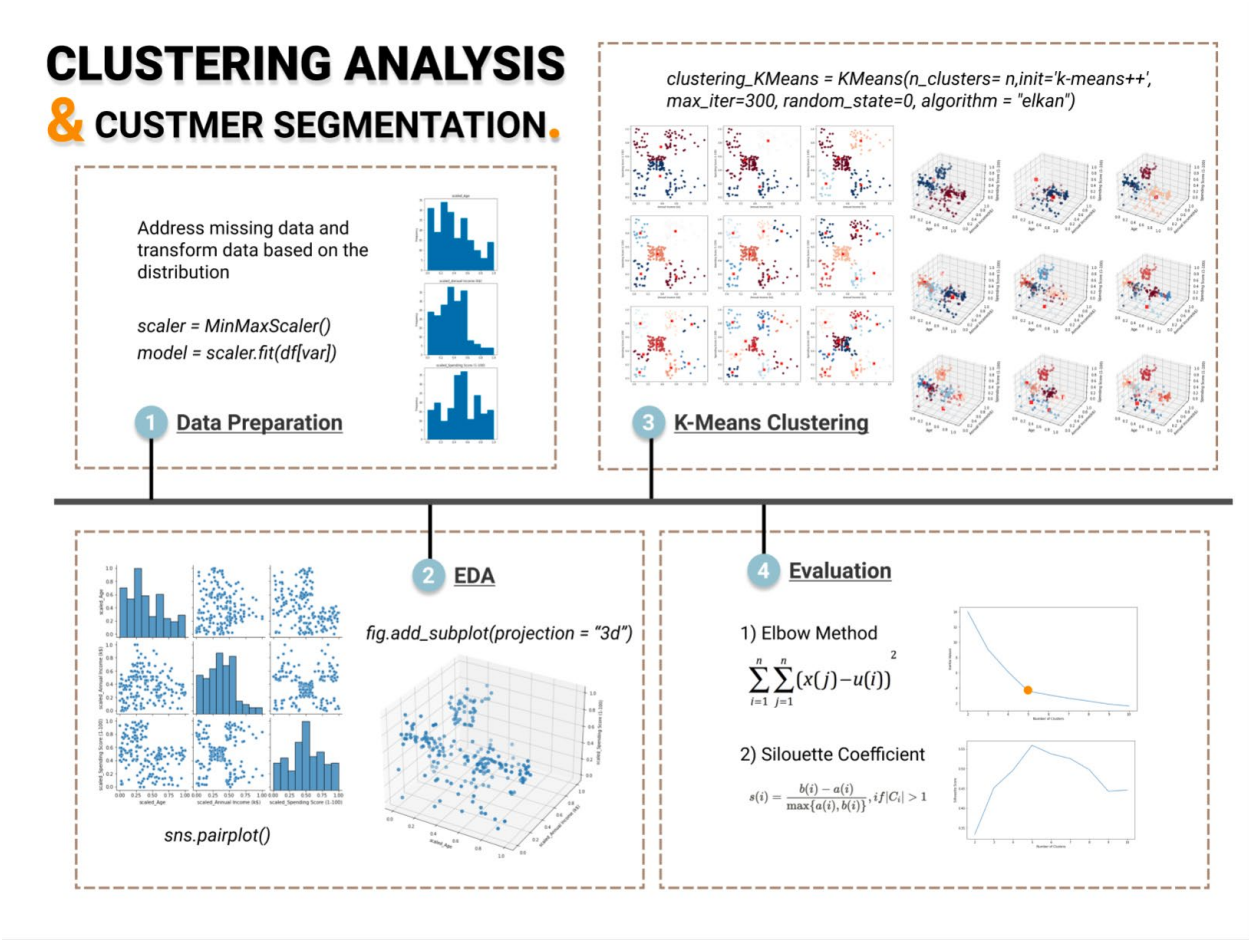

towardsdatascience.com

Thuật toán phân cụm cho phân đoạn khách hàng.

- **Phân cấp (Hierarchical)**: Xây dựng cây phân cấp (dendrogram) bằng cách hợp nhất hoặc chia cụm. Có hai cách: agglomerative (từ dưới lên) và divisive (từ trên xuống).

Ví dụ thực tế: Trong sinh học, phân cấp dùng để nhóm gen dựa trên biểu hiện, giúp phát hiện gen liên quan ung thư.

- **Dựa trên mật độ (DBSCAN)**: Nhóm điểm có mật độ cao, loại bỏ nhiễu. Phù hợp dữ liệu không đều.

Ví dụ thực tế: Phân tích dữ liệu vị trí GPS để xác định khu vực tắc nghẽn giao thông ở Hà Nội.

Phương pháp	**Ưu điểm**	**Nhược điểm**	**Ứng dụng thực tế**
K-means	Nhanh, dễ triển khai	Cần chỉ định k trước, nhạy cảm nhiễu	Phân đoạn khách hàng (Netflix, Amazon)
Hierarchical	Không cần k trước, hiển thị cây	Chi phí cao cho dữ liệu lớn	Phân cụm gen (nghiên cứu y học)
DBSCAN	Xử lý nhiễu tốt, cụm hình thù bất kỳ	Khó chọn tham số	Phân tích giao thông (Google Maps)

7. Kết luận và câu hỏi/ bài tập

Phân nhóm và phân đoạn là công cụ mạnh mẽ trong khai phá dữ liệu, giúp khám phá insight từ dữ liệu không có nhãn. Để áp dụng hiệu quả, cần chọn độ đo và phương pháp phù hợp với dữ liệu.

Câu hỏi/Thực hành:

1. Phân biệt phân cụm và phân loại?
2. Liệt kê 3 ứng dụng thực tế của phân cụm và giải thích.
3. Mô tả thuật toán K-means với ví dụ.